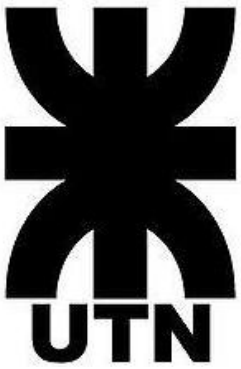
UNIVERSIDAD TECNOLÓGICA NACIONAL

Facultad Regional Córdoba — Ingeniería en Sistemas de Información

Trabajo Práctico Integrador — Ciencia de Datos

Entrega 1: Planificación y obtención de datos



Análisis de los determinantes del precio en servicios de movilidad bajo demanda: el caso de Uber y Lyft en Boston, Massachusetts

Cátedra	Ciencia de Datos
Curso	5K1
Docente/s	Marisa del Carmen Callejas
Integrantes	Alvaro Perez 97986 Juan Ignacio Cremona 95789 Ignacio Gil 407114 Federico Gon 94470 Sofía Medina 88655 Facundo Dagnino Dailly 94307
Fecha de entrega	11 de septiembre de 2026
Modalidad	Grupal — informe en formato paper científico y defensa oral

Índice

1. Resumen
2. Introducción y contexto del problema
3. Objetivo general
4. Dataset seleccionado
    - 4.1. Identificación y origen
    - 4.2. Estructura y descripción de las variables
    - 4.3. Justificación de la selección
    - 4.4. Insights esperados
5. Metodología de trabajo
    - 5.1. Ciclo de vida del proyecto
    - 5.2. Marco de gestión: Scrum
6. Plan de proyecto
    - 6.1. Cronograma general
    - 6.2. Detalle del Sprint 1
7. Conclusiones y próximos pasos
8. Referencias

1. Resumen

Este trabajo es la primera entrega del Trabajo Práctico Integrador. El objetivo principal es definir el alcance del proyecto, armar el plan de trabajo y presentar la base de datos con la que vamos a estar trabajando a lo largo del cuatrimestre. La idea es analizar qué factores influyen en el precio final de las aplicaciones de viajes, usando como caso de estudio el dataset público "Uber and Lyft Dataset Boston, MA". Este conjunto incluye 693.071 registros de viajes realizados entre el 26 de noviembre y el 18 de diciembre de 2018, combinados con datos del clima hora por hora en Boston.

Para la organización seguimos las etapas típicas de un proyecto de ciencia de datos y nos apoyamos en el marco ágil Scrum, dividiendo el trabajo en cuatro sprints que coinciden con las entregas de la materia. En este primer documento dejamos asentada la elección del dataset, sus características, los objetivos que buscamos alcanzar, los hallazgos que esperamos encontrar y los riesgos del proyecto junto con sus estrategias para resolverlos.

2. Introducción y contexto del problema

Las plataformas de movilidad bajo demanda —comúnmente denominadas ride-hailing— modificaron de manera profunda la forma en que se organiza el transporte urbano de pasajeros. A diferencia del taxi tradicional, cuya tarifa suele estar regulada y ser previsible, empresas como Uber y Lyft calculan el precio de cada viaje mediante algoritmos que combinan la distancia y duración estimadas, la categoría del servicio solicitado y un factor de ajuste por demanda instantánea, conocido como surge pricing o prime time.

Esta falta de transparencia genera un problema concreto para los distintos actores del ecosistema. Para el pasajero, la dificultad de anticipar cuánto costará un viaje y de identificar cuándo conviene esperar o cambiar de plataforma. Para el conductor, la incertidumbre respecto de en qué zonas y franjas horarias resulta más rentable operar. Y para la propia empresa, la necesidad de calibrar sus políticas tarifarias de modo que maximicen los ingresos sin deteriorar la demanda ni la percepción de equidad del servicio.

Por eso, en este trabajo nos preguntamos: ¿qué factores influyen en el precio de un viaje y qué tan bien podemos predecirlo usando datos pasados de los viajes y del clima? La idea es dejar de lado las suposiciones y entender con datos reales cómo funciona la tarifa.

3. Objetivo general

Identificar y cuantificar los factores que influyen en el precio de los viajes de Uber y Lyft, extraer patrones significativos y analizar la posibilidad de predecir su comportamiento a partir de datos históricos de viajes y clima.

3.1 Objetivos específicos

- Explorar y caracterizar el comportamiento de los precios de los viajes de Uber y Lyft, considerando variables como distancia, tipo de servicio, empresa, ubicación y momento del día.
- Identificar los principales factores asociados a las variaciones en el precio de los viajes y determinar qué variables presentan mayor relación con la tarifa final.

- Analizar patrones temporales y geográficos en los precios, considerando horarios, días de la semana, recorridos entre zonas y posibles diferencias entre períodos de mayor y menor demanda.
- Comparar el comportamiento tarifario de Uber y Lyft en condiciones de viaje similares, identificando diferencias según el tipo de servicio, distancia y momento del viaje.
- Identificar segmentos o perfiles de viajes con comportamientos tarifarios similares mediante técnicas de análisis exploratorio y, si resulta pertinente, de agrupamiento.
- Comunicar los principales hallazgos mediante visualizaciones y herramientas de data storytelling que permitan interpretar los resultados y extraer conclusiones relevantes para usuarios y operadores de servicios de movilidad.

4. Dataset seleccionado

4.1. Identificación y origen

El conjunto de datos seleccionado es "Uber and Lyft Dataset Boston, MA", publicado por el usuario brllrb en la plataforma Kaggle. Los datos fueron recolectados mediante consultas periódicas a las interfaces públicas de estimación de tarifas de ambas plataformas, complementadas con registros meteorológicos horarios correspondientes a las mismas ubicaciones y momentos.

Atributo	Detalle
Nombre	Uber and Lyft Dataset Boston, MA
Fuente	https://www.kaggle.com/datasets/brllrb/uber-and-lyft-dataset-boston-ma
Cobertura geográfica	Ciudad de Boston, Massachusetts, Estados Unidos (12 zonas de origen y destino)
Cobertura temporal	26/11/2018 al 18/12/2018
Volumen	693.071 registros
Cantidad de variables	57 columnas
Variable objetivo	price (costo del viaje, en dólares estadounidenses)
Formato	Archivos CSV
Granularidad	Un registro por consulta de tarifa (viaje–producto–instante)

4.2. Estructura y descripción de las variables

Las 57 columnas pueden agruparse en cuatro bloques temáticos, lo que facilita tanto su comprensión como la posterior selección de variables:

Bloque	Variables representativas	Descripción
Identificación y tiempo	id, timestamp, datetime, hour, day, month, timezone	Identificador único de la consulta y marcas temporales asociadas.

Bloque	Variables representativas	Descripción
Viaje y servicio	source, destination, distance, cab_type, product_id, name, price, surge_multiplier	Origen y destino del recorrido, distancia, empresa (Uber o Lyft), categoría de producto y precio.
Ubicación	latitude, longitude	Coordenadas geográficas asociadas al registro.
Condiciones meteorológicas	temperature, apparentTemperature, humidity, windSpeed, windGust, visibility, precipIntensity, precipProbability, cloudCover, pressure, uvIndex, dewPoint, ozone, short_summary, long_summary y derivadas (máximos, mínimos y sus marcas de tiempo)	Estado del tiempo en el momento y lugar del viaje, junto con un amplio conjunto de agregados diarios derivados.

Variable objetivo. La variable a predecir es *price*, que representa el precio del viaje expresado en dólares. Se trata de una variable numérica continua, por lo que el problema principal se plantea como una tarea de regresión supervisada. Además, se usarán variables categóricas (por ejemplo, si hubo o no tarifa dinámica observándose en la columna surge_multiplier) para complementar con modelos de clasificación.

4.3. Justificación de la selección

La elección del conjunto de datos responde a los siguientes criterios:

- **Cumplimiento holgado del requisito de volumen.** Con 693.071 registros, el conjunto supera ampliamente el mínimo de 20.000 filas exigido por la cátedra, lo que permite trabajar con particiones de entrenamiento y prueba robustas y realizar validación cruzada sin comprometer el tamaño muestral.
- **Riqueza y diversidad de variables.** La coexistencia de variables numéricas, categóricas, temporales, geográficas y meteorológicas habilita un análisis exploratorio profundo y el ensayo de distintas técnicas de ingeniería de atributos.
- **Relevancia y comprensibilidad del dominio.** El problema del precio en plataformas de movilidad resulta cercano y comprensible para cualquier audiencia, lo que favorece la construcción de una narrativa clara en la etapa de data storytelling.
- **Accesibilidad y licenciamiento.** Los datos son de acceso público y gratuito, no contienen información personal identificable de pasajeros ni conductores, y su uso con fines académicos no plantea conflictos éticos ni legales.

4.4. Insights esperados

A partir del análisis se espera obtener, entre otros, los siguientes hallazgos:

- Análisis de los principales factores asociados al precio del viaje, evaluando el peso relativo de la distancia, la categoría de servicio y otras características del viaje.
- La comparación sistemática entre Uber y Lyft en recorridos equivalentes, identificando en qué segmentos de servicio y en qué franjas horarias una plataforma resulta más conveniente que la otra.

- La caracterización de los patrones temporales de la demanda y del recargo por hora del día y día de la semana.
- Identificación de los corredores origen–destino con mayor costo por kilómetro y análisis de su posible relación con las características geográficas de los recorridos.
- La evaluación empírica de la hipótesis de que las condiciones meteorológicas adversas incrementan el precio, contrastándola con la magnitud real del efecto observado en los datos.
- La segmentación de los viajes en grupos con comportamiento tarifario homogéneo, útil para caracterizar perfiles de uso del servicio.

5. Metodología de trabajo

5.1. Ciclo de vida del proyecto

El proyecto se estructura sobre las etapas clásicas del ciclo de vida de un proyecto de ciencia de datos, en línea con el estándar CRISP-DM: comprensión del negocio y del problema, comprensión y adquisición de los datos, preparación de los datos, modelado, evaluación y comunicación de resultados. Estas etapas se corresponden de manera directa con las cuatro entregas previstas por la cátedra.

5.2. Marco de gestión: Scrum

La gestión del trabajo se realiza mediante el marco ágil Scrum, adaptado a la escala y duración del proyecto académico. Se definen sprints cuya duración coincide con los intervalos entre entregas, de modo que cada entrega constituye el incremento entregable del sprint correspondiente.

Rol	Responsabilidad
Product Owner	Representa los objetivos analíticos y las expectativas de la cátedra; prioriza el backlog y valida los incrementos.
Scrum Master	Facilita las ceremonias, remueve impedimentos y vela por el cumplimiento de plazos.
Equipo de desarrollo	Ejecuta las tareas de adquisición, preparación, modelado, documentación y presentación.

Para la gestión del proyecto se adaptaron las ceremonias estándar del marco Scrum. De esta manera, cada sprint incluye las instancias de planificación (*Sprint Planning*), seguimiento periódico (*Daily Standup*), revisión de los entregables (*Sprint Review*) y retrospectiva (*Sprint Retrospective*), garantizando una organización ágil y continua.

6. Plan de proyecto

6.1. Cronograma general

Sprint	Entrega	Objetivo del incremento	Fecha (tentativo)
1	Entrega 1	Planificación del proyecto y obtención del dataset	11/09/2026

Sprint	Entrega	Objetivo del incremento	Fecha (tentativo)
2	Entrega 2	Limpieza y preparación de datos (ETL)	02/10/2026
3	Entrega 3	Modelado y análisis de resultados	30/10/2026
4	Entrega 4	Presentación final (data storytelling)	06, 11, 13 o 18/11/2026

6.2. Detalle del Sprint 1

Tarea	Responsable	Estado
Definición del problema, la pregunta de investigación y los objetivos	[Product owner]	Finalizada
Búsqueda y comparación de datasets candidatos	[Equipo de desarrollo]	Finalizada
Verificación de volumen, licencia y pertinencia del dataset elegido	[Equipo de desarrollo]	Finalizada
Documentación de estructura, variables y justificación	[Juan Ignacio Cremona]	Finalizada
Redacción del informe y preparación de la defensa oral	[Equipo de desarrollo]	Finalizada

7. Conclusiones y próximos pasos

En esta primera entrega se definieron el problema a abordar, los objetivos generales y específicos, y el plan de trabajo bajo el marco Scrum, con un cronograma alineado a las cuatro entregas previstas por la cátedra. Se seleccionó y documentó el conjunto de datos "Uber and Lyft Dataset Boston, MA", que satisface holgadamente los requisitos de volumen y ofrece una combinación de variables operativas, temporales, geográficas y meteorológicas apropiada para los objetivos planteados.

El Sprint 2 se orientará a la ejecución del proceso de ETL: análisis exploratorio estadístico y visual, evaluación de la calidad de los datos, integración de las fuentes de viajes y clima, tratamiento fundamentado de valores faltantes e inconsistentes, y selección de variables, con el fin de obtener el dataset objetivo listo para modelar.

8. Referencias

Cátedra de Ciencia de Datos (2026). Trabajo Práctico Integral – Proyecto de Ciencia de Datos. Universidad Tecnológica Nacional, Facultad Regional Córdoba.

Kaggle. Uber and Lyft Dataset Boston, MA. Recuperado de https://www.kaggle.com/datasets/brllrb/uber-and-lyft-dataset-boston-ma

Schwaber, K. y Sutherland, J. (2020). La Guía de Scrum: la guía definitiva de Scrum, las reglas del juego.

Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.

Provost, F. y Fawcett, T. (2013). Data Science for Business. O'Reilly Media.