UNIVERSIDAD TECNOLÓGICA NACIONAL

Facultad Regional Córdoba — Ingeniería en Sistemas de Información

Trabajo Práctico Integrador — Ciencia de Datos

Entrega 2: Limpieza y preparación de datos (ETL)

Análisis de los determinantes del precio en servicios de movilidad bajo demanda: el caso de Uber y Lyft en Boston, Massachusetts

Cátedra	Ciencia de Datos
Curso	5K1
Docente/s	Marisa del Carmen Callejas
Integrantes	Álvaro Pérez 97986 Juan Ignacio Cremona 95789 Ignacio Gil 407114 Federico Gon 94470 Sofía Medina 88655 Facundo Dagnino Dailly 94307
Fecha de entrega	2 de octubre de 2026
Modalidad	Grupal — informe en formato paper científico y defensa oral

Índice

1. Resumen
2. Cambio de alcance: la nueva variable objetivo
    2.1. Qué es has_surge
    2.2. Por qué genera valor
    2.3. Por qué binaria y por qué solo Lyft
    2.4. Riesgos y cómo los controlamos
3. Lo que descubrimos sobre el dataset
4. Análisis exploratorio (EDA)
    4.1. Objetivo 1: price
    4.2. Objetivo 2: has_surge
5. Calidad de los datos en cinco dimensiones
6. Tratamiento: tabla de decisiones
7. Integración de fuentes
    7.1. Viajes y clima
    7.2. Fuente externa: OpenStreetMap
8. Selección e ingeniería de variables
9. Datasets resultantes
10. Plan de proyecto
    10.1. Detalle del Sprint 2
    10.2. Próximos pasos: Sprint 3 (Modelado, 30/10)
11. Referencias

1. Resumen

Esta segunda entrega cubre la limpieza y preparación de los datos (ETL) del proyecto. A partir de la devolución de la cátedra sumamos una **segunda variable objetivo**: *has_surge*, que indica si una cotización de Lyft tiene recargo por demanda. El objetivo 1 (*price*) explica **cuánto** cuesta un viaje. El nuevo objetivo explica **cuándo y dónde** se paga de más: cuando hay recargo, el mismo viaje cuesta en promedio un 46% más.

Sobre el archivo original (693.071 registros y 57 columnas) hicimos un análisis exploratorio, evaluamos la calidad en las cinco dimensiones comprometidas en la Entrega 1 y tomamos 16 decisiones documentadas. En el proceso aparecieron tres problemas que no eran visibles a simple vista: la hora del dataset está en UTC y no en hora de Boston; el clima se unió por hora y no por zona; y faltan fechas completas. El resultado es un dataset limpio de **636.568 filas y 27 columnas** (con *has_surge* incluida) y dos subconjuntos listos para modelar en la Entrega 3.

2. Cambio de alcance: la nueva variable objetivo

2.1. Qué es has_surge

Las plataformas aplican un **recargo dinámico** (*surge_multiplier*) cuando la demanda supera a la oferta: el precio se multiplica por 1,25; 1,5; 2 o más. Definimos **has_surge = 1 si surge_multiplier > 1, y 0 en caso contrario**. Es un problema de **clasificación binaria** que se trabaja solo con los viajes de Lyft, sin el producto Shared.

	Objetivo 1 (sin cambios)	**Objetivo 2 (nuevo)**
Variable	*price* (USD)	*has_surge* (0/1)
Pregunta	¿Cuánto cuesta el viaje?	¿Este viaje tiene recargo?
Tipo de problema	Regresión supervisada	Clasificación binaria
Datos	Uber + Lyft · 636.568 filas	Lyft sin Shared · 255.953 filas

2.2. Por qué genera valor

El análisis exploratorio muestra que el precio es, en gran parte, **estructural**: el producto elegido y la distancia explican juntos el **91,8%** de su variación. Lo que el pasajero no puede anticipar es la parte **dinámica**: el recargo, que cambia el precio *del mismo viaje* según el momento y la zona. *has_surge* aísla esa parte y la convierte en una pregunta propia. Los datos muestran por qué vale la pena:

- **Impacto económico concreto.** Cuando hay recargo, el multiplicador promedio es ×1,46: el viaje cuesta en promedio un **46% más**. Según el producto, el precio mediano observado sube entre un 36% y un 67% (Figura 1).
- **Es frecuente.** El **8,19%** de las cotizaciones de Lyft (sin Shared) tiene recargo: aproximadamente 1 de cada 12.
- **Tiene patrones que se pueden aprender.** La tasa de recargo varía **7,3 veces** según la zona de origen: de 1,8% en North End a 13,4% en Back Bay (Figura 7).
- **Sirve a cada actor del problema.** Al **pasajero**, para decidir si esperar, caminar a otra zona o cambiar de plataforma (Uber no informa recargo). Al **conductor**, para saber dónde ubicarse. A la **plataforma**, para anticipar dónde falta oferta.

- **Completa la historia del precio.** El objetivo 1 explica la parte estructural (producto y distancia) y el objetivo 2, la parte dinámica. Juntos ordenan el *storytelling* de la Entrega 4.

Incluso un resultado modesto en la Entrega 3 sería un hallazgo: significaría que el recargo no se puede anticipar solo con hora, zona, producto y clima, porque depende de la demanda en tiempo real (pedidos y conductores disponibles), que no está en el dataset.

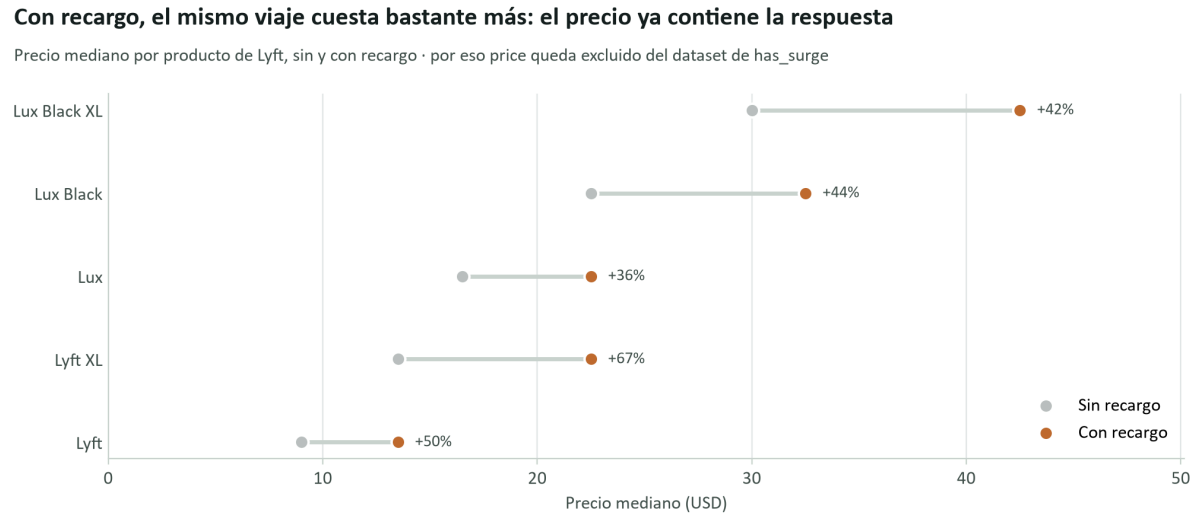


Figura 1. *Precio mediano por producto de Lyft, sin y con recargo. El recargo encarece el mismo viaje de forma marcada.*

2.3. Por qué binaria y por qué solo Lyft

Antes de definir la variable verificamos con los datos cada supuesto. Las cifras reales reemplazan a las estimaciones iniciales:

Decisión	Evidencia en los datos
Trabajar solo con Lyft	En Uber, *surge_multiplier* vale 1 en los 385.663 registros: la variable no informa nada.
No usar regresión sobre el multiplicador	El 97,0% de los registros vale 1,0: el modelo tendería a predecir siempre 1,0.
No usar multiclase	Las clases altas casi no tienen casos: ×2,5 ⟶ 154 y ×3 ⟶ 12.
Reformular como binaria	La clase positiva junta todos los recargos: 20.975 casos (8,19%).
Excluir Lyft Shared	Nunca tiene recargo (0 de 51.233). Incluirlo agregaría ceros garantizados: una regla trivial y más desbalance (6,82% en lugar de 8,19%).
Alternativa a futuro	Tres clases: sin recargo (1,0), leve (1,25–1,5) y alto (≥ 1,75).

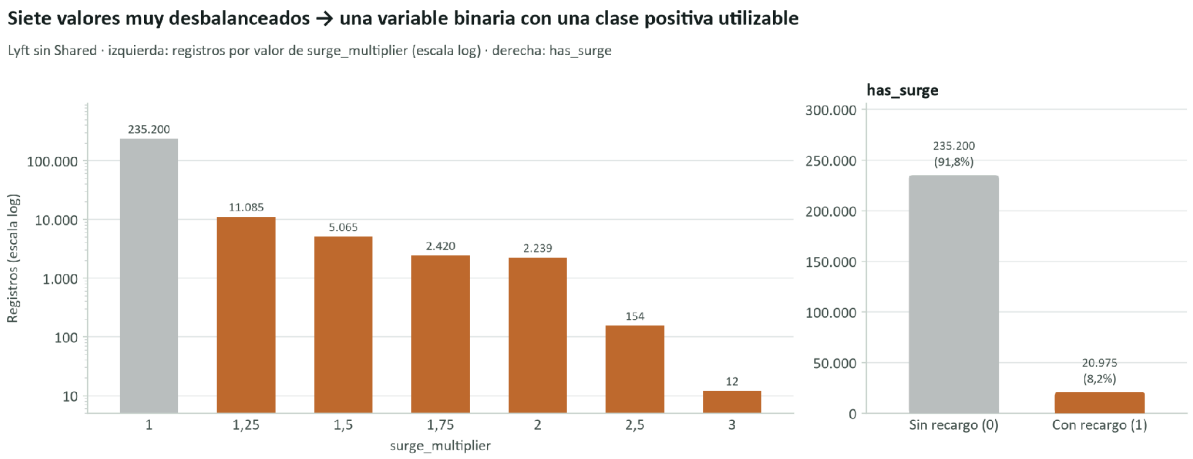


Figura 2. *Distribución de surge_multiplier en Lyft sin Shared (escala logarítmica) y su versión binaria has_surge.*

2.4. Riesgos y cómo los controlamos

- **Fuga de datos** (*data leakage*). El precio ya incluye el recargo, así que *price*, *surge_multiplier* y cualquier variable derivada de ellos **se excluyen** del dataset de *has_surge*. El modelo tiene que anticipar el recargo, no leerlo del precio.
- **surge_multiplier para predecir price.** Se **conserva** en el dataset de precio, porque la app lo muestra al cotizar (no es información del futuro). En la Entrega 3 entrenaremos con y sin esta variable para medir cuánto aporta.
- **Filas no independientes.** En el 95,7% de los grupos (ruta, minuto), todos los productos comparten el valor de *has_surge*: el recargo es de la zona y el momento, no del producto. Para no inflar las métricas, la validación se va a **agrupar por fecha**.

3. Lo que descubrimos sobre el dataset

Kaggle distribuye el dataset como **un único archivo ya unido** (*rideshare_kaggle.csv*), no como viajes y clima por separado. Antes de limpiar verificamos qué representa cada columna. Encontramos tres problemas que cambian el análisis:

Hallazgo	Evidencia	Consecuencia
La hora está en UTC (hora de referencia mundial), no en hora de Boston (UTC − 5 h)	*hour* coincide con la hora UTC en el 100% de las filas y con la local en el 0%, aunque *timezone* dice America/New_York.	Recalculamos la hora local (UTC − 5 h). Sin esta corrección, todos los patrones horarios quedarían corridos.
El clima se unió por hora, no por zona	Hay un solo registro de clima por hora (332 horas). 11 de las 12 coordenadas caen sobre una zona, pero cada hora recibe el clima de *una sola* zona, que coincide con el origen del viaje solo en el 8,4% (igual que el azar).	*latitude* y *longitude* no describen el viaje y se descartan. El clima se usa como contexto de la ciudad por hora.
Faltan fechas	De 24 fechas (hora local) hay datos en 18, y solo 14 están completas. No hay registros del 05/12, 06/12, 07/12, 08/12, 10/12 y 11/12.	Cada día de la semana queda representado por pocas fechas: las conclusiones por día se toman con cautela. Corrige los "23 días de cobertura" de la Entrega 1.

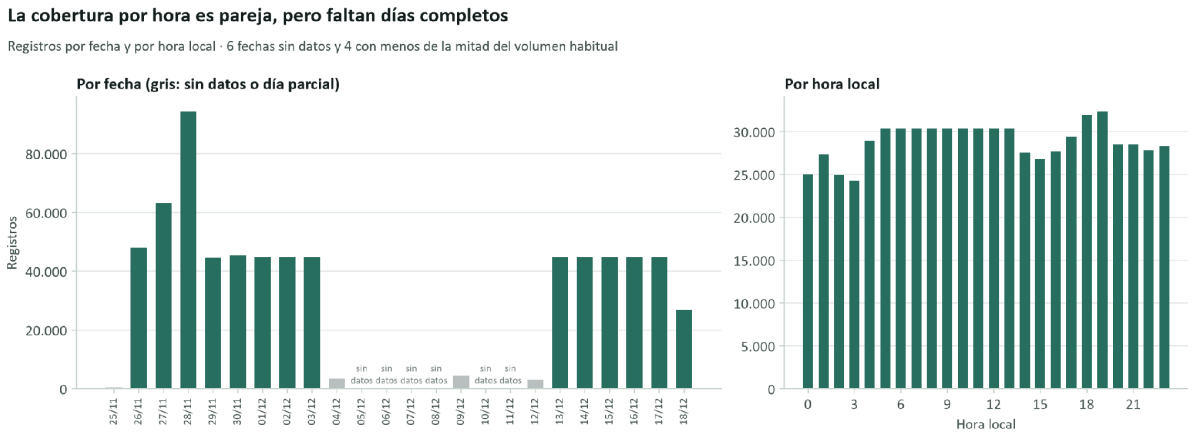


Figura 3. *Registros por fecha y por hora local. La cobertura por hora es pareja, pero faltan días completos.*

4. Análisis exploratorio (EDA)

4.1. Objetivo 1: price

Estadísticos descriptivos de las variables numéricas principales (registros con precio, antes de la limpieza):

Variable	n	Media	Mediana	Desvío	Mín.	Máx.	Asimetría
Precio (USD) · total	637.976	16,55	13,50	9,32	2,50	97,50	1,05
Precio (USD) · Uber	330.568	15,80	12,50	8,56	4,50	89,50	1,05
Precio (USD) · Lyft	307.408	17,35	16,50	10,02	2,50	97,50	0,98
Distancia (millas)	637.976	2,19	2,16	1,14	0,02	7,86	0,82

- **Distribución:** el precio tiene asimetría a la derecha (coeficiente 1,05): la mayoría de los viajes son baratos y unos pocos son muy caros. Con logaritmo la asimetría baja a −0,10 (Figura 4). **Decisión:** modelar *log(price)* en la Entrega 3.

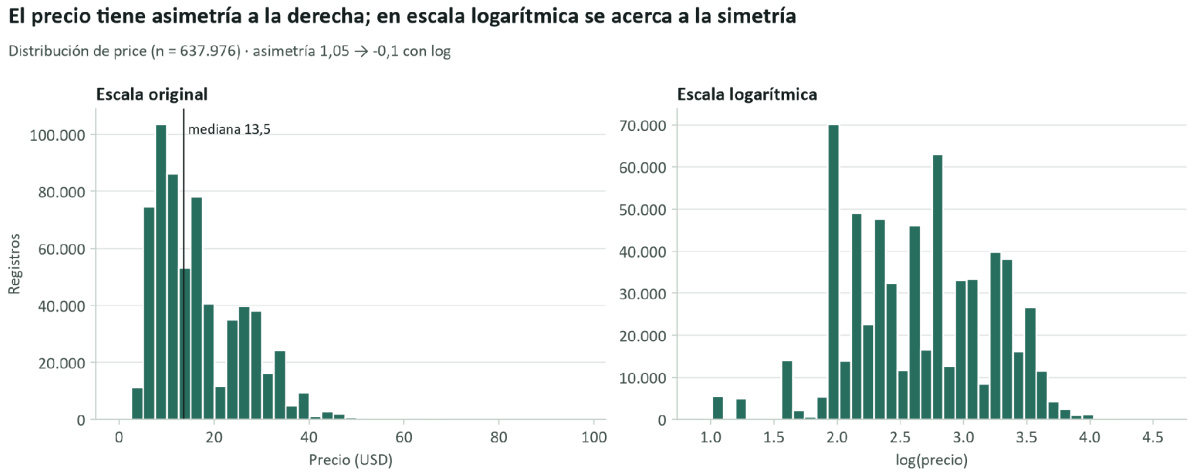


Figura 4. *Distribución del precio en escala original y logarítmica. La transformación logarítmica corrige la asimetría.*

- **Peso de cada factor (H1):** el producto explica por sí solo el 77,4% de la variación del precio, la distancia el 11,9% y el recargo el 5,8%. Hora, día y clima explican prácticamente nada (Figura 5).

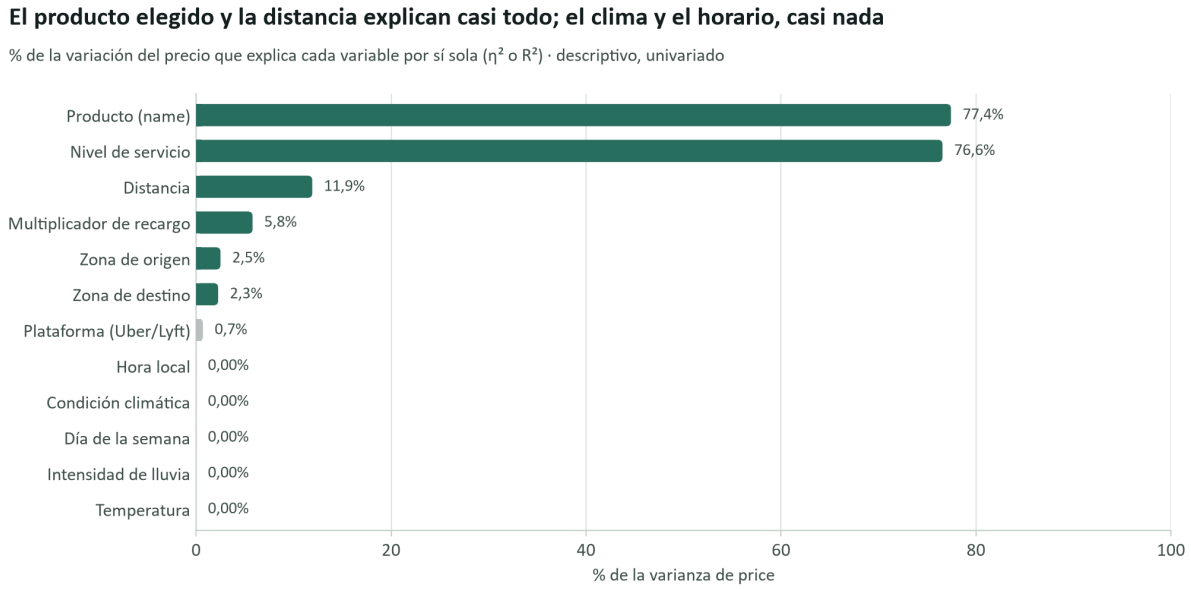


Figura 5. Porcentaje de la variación del precio que explica cada variable por sí sola (η² para categóricas, R² para numéricas).

- **Uber vs Lyft (H2):** a igual distancia y en niveles equivalentes (sin recargo), Lyft es más barato en los económicos (Compartido −17,6%, Estándar −5,3%, XL −10,0%) y más caro en los Black (Black +15,4%, Black XL +5,3%). La relación precio–distancia crece por escalones, no en línea recta (Figura 6): conviene probar modelos de árboles, que capturan relaciones no lineales.

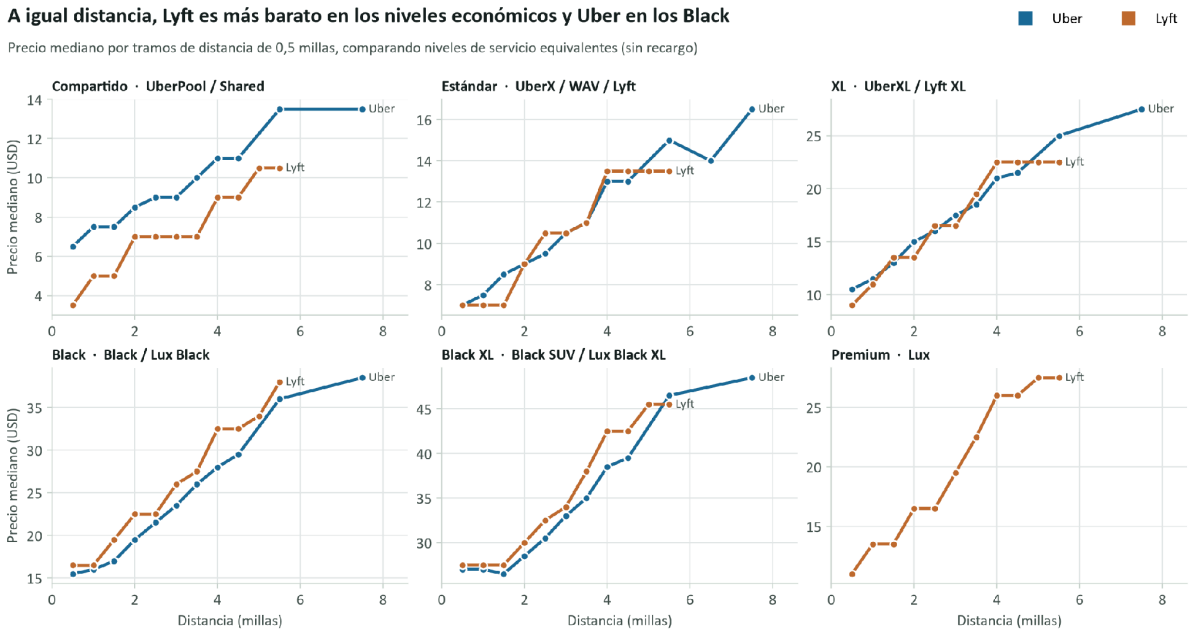


Figura 6. Precio mediano por tramos de distancia, comparando Uber y Lyft en niveles de servicio equivalentes (sin recargo).

- **Corredores (H4):** el precio por milla más alto está en Financial District ⟶ South Station (USD 17,95/milla), una ruta de 0,39 millas: en los viajes cortos pesa la tarifa base.

- **Clima (H5):** no muestra relación lineal con el precio (|r| máximo = 0,0015). Se conserva un conjunto reducido de variables para probar efectos no lineales en la Entrega 3.

4.2. Objetivo 2: has_surge

- **Zona de origen:** es el factor más claro, con una tasa que va de 1,8% (North End) a 13,4% (Back Bay). Back Bay, Northeastern University, Fenway, Boston University y Theatre District superan el 11%, mientras que West End, North Station, Haymarket Square y North End no llegan al 5%.
- **Hora (H3):** variación moderada, entre 7,0% (11 h) y 9,6% (8 h). En hora pico el recargo es de 8,5% y fuera de ella, 8,1%. Por día de la semana las diferencias son mínimas.
- **Producto:** los cinco productos de Lyft con recargo tienen la misma tasa (8,19%) y Shared tiene 0%: el recargo depende de la zona y el momento.
- **Clima:** sin efecto visible (con lluvia 7,85% frente a 8,28% sin lluvia).

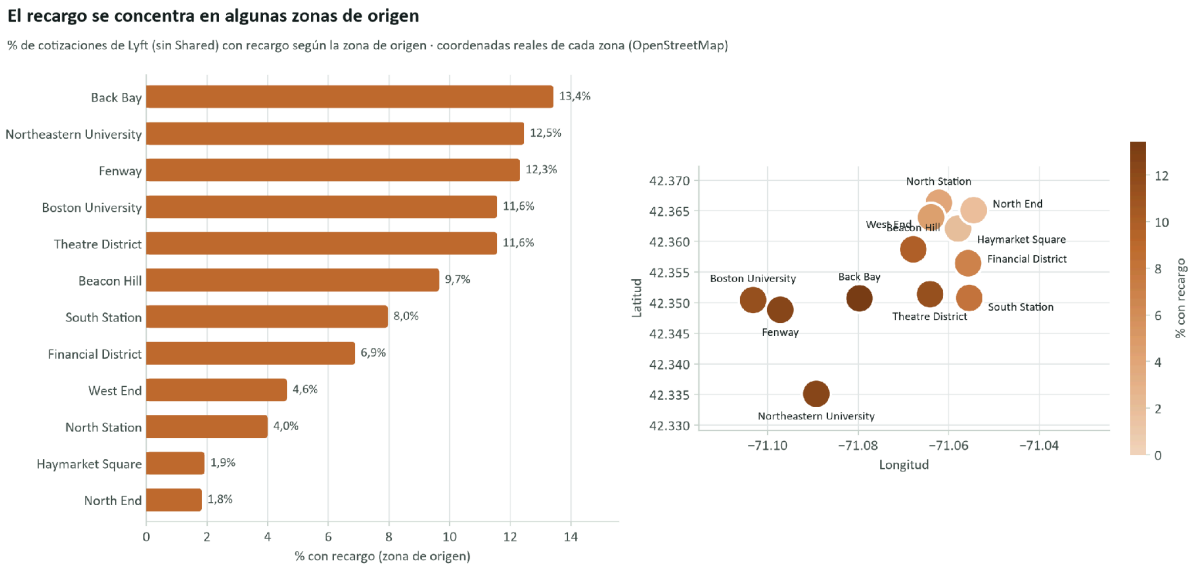


Figura 7. *Porcentaje de cotizaciones de Lyft (sin Shared) con recargo según la zona de origen, con las coordenadas reales de cada zona (OpenStreetMap).*

5. Calidad de los datos en cinco dimensiones

Tal como nos comprometimos en la Entrega 1, medimos la calidad antes de limpiar. Cada dimensión termina en una decisión (sección 6).

Dimensión	Resultado medido	Acción
Completitud	55.095 nulos (7,95%), solo en price; 100% de Taxi y 0 en el resto	Eliminar Taxi
Validez	9 de 10 reglas sin violaciones; 406 distancias < 0,1 mi entre zonas distintas. Atípicos de precio (IQR por producto): 21.665, 85,4% explicados por recargo/distancia	Eliminar distancias implausibles; conservar atípicos reales
Consistencia	Tiempo: 1 registro de clima por hora (100%). Lugar: cada hora recibe el clima de una sola zona; lat/long no son del viaje (coinciden con el origen en 8,4%). hour en UTC (100%)	Hora local; descartar lat/long; clima como contexto horario de la ciudad
Unicidad	1.677 copias de una misma cotización (1.046 exactas y 631 que difieren solo en fracciones de segundo); 13.378 filas con igual clave pero distinto precio/distancia	Eliminar copias; conservar cotizaciones distintas

Dimensión	Resultado medido	Acción
Cobertura temporal	Por hora: pareja (coeficiente de variación 0,074). Por día: 18 de 24 fechas con datos, 4 parciales	No imputar; documentar y validar agrupando por fecha

Criterio de outliers. Usamos el rango intercuartílico (Tukey, k = 1,5) **dentro de cada producto**, porque un IQR global marcaría como "atípicos" a 5.589 viajes premium normales. De los 21.665 atípicos, el 85,4% se explica por recargo o por una distancia larga: son precios reales, el fenómeno que queremos modelar. Por eso se conservan (Figura 8).

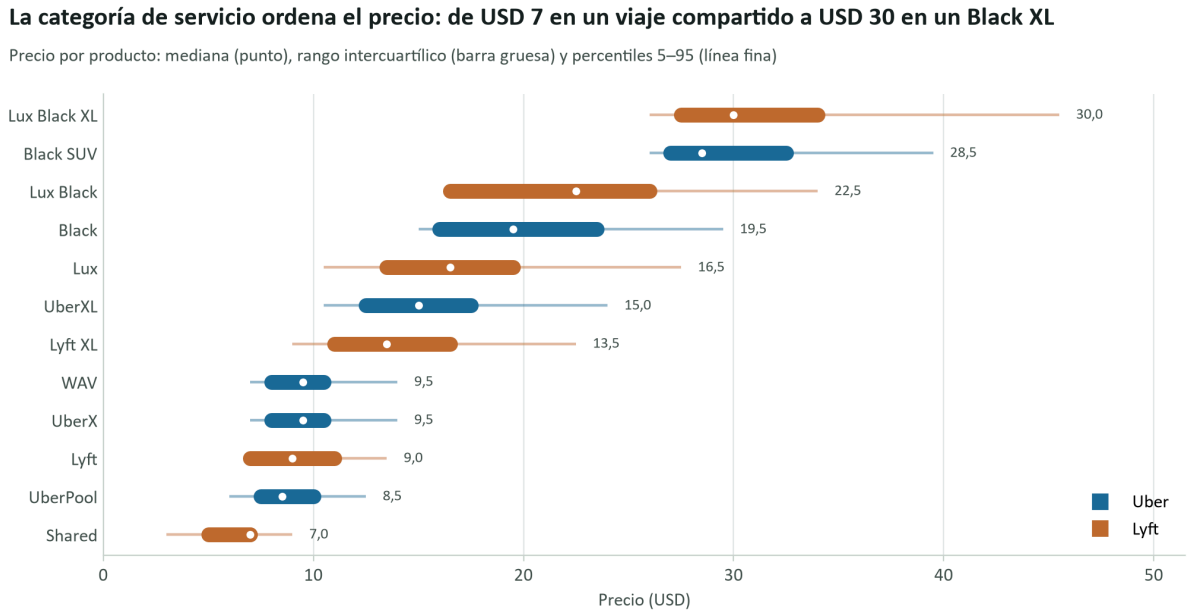


Figura 8. *Precio por producto: mediana, rango intercuartílico y percentiles 5–95. Cada producto tiene su propio rango, por eso los atípicos se buscan dentro de cada uno.*

6. Tratamiento: tabla de decisiones

Cada problema tiene una estrategia, una justificación y un impacto medido. El registro completo está en *reports/log_decisiones.csv*.

#	Problema	Estrategia	Justificación	Impacto
D01	55.095 nulos en price, todos en Taxi (100% del producto)	Eliminar el producto Taxi completo	Faltante estructural, no aleatorio: no hay ningún precio de Taxi para imputar con fundamento. Imputar inventaría tarifas de un producto sin referencia.	−55.095 filas
D02	Registros idénticos en todo salvo id (incluye los que difieren solo en fracciones de segundo del timestamp)	Eliminar copias (se conserva la primera)	Son la misma cotización repetida: duplicarla sobrerrepresenta ese instante.	−1.060 filas
D03	13.378 filas comparten ruta, producto y timestamp pero difieren en precio/distancia	Conservar	Son cotizaciones distintas (otro punto exacto dentro de la zona), no duplicados.	Sin cambios

#	Problema	Estrategia	Justificación	Impacto
D04	Distancias de 0,02–0,04 mi entre zonas distintas (solo Uber)	Eliminar registros con distance < 0,1 mi	Físicamente incoherentes con la separación real entre zonas (fuente externa OSM); en Lyft la mínima es 0,39 mi. Distorsionan la relación precio–distancia.	−348 filas
D05	21.665 atípicos de price (IQR por producto, k = 1,5)	Conservar; tratar la asimetría con log(price) en el modelado	El 85,4% se explica por recargo o distancia larga: son precios reales, el fenómeno a modelar.	Sin cambios
D06	hour/day/month/datetime en UTC; timezone constante e incorrecto	Reemplazar por datetime_local, hour_local, day_of_week (America/New_York) y descartar las originales	Sin corrección, todos los patrones horarios quedarían corridos 5 h.	−6 col.
D07	latitude/longitude son la ubicación del registro de clima, no del viaje	Descartar; usar coordenadas reales de las zonas (OSM) si se necesitan	Usarlas como ubicación del viaje sería un error de interpretación.	−2 col.
D08	visibility.1 = visibility (100%); product_id ↔ name 1 a 1	Descartar visibility.1 y product_id	No aportan información nueva.	−2 col.
D09	Viajes y clima vienen unidos sin documentar la clave	Separar en viajes + clima horario y volver a unir por hora_utc (validación m:1)	El clima es único por hora (332 horas); la unión reproduce el 100% de los valores originales.	Sin cambios
D10	No hay ubicación real de las zonas	Incorporar coordenadas de OpenStreetMap y derivar straight_line_miles	Fuente externa abierta y reproducible; permite validar distancias y describir la ruta numéricamente.	+1 col.
D11	40 columnas de clima con agregados diarios, marcas de tiempo y pares |r| > 0,85	Conservar 9 variables climáticas horarias y descartar 31	Se eliminan duplicados de información (|r| > 0,85), agregados diarios, marcas de tiempo y variables sin relación plausible; la máxima |r| entre las que quedan es baja.	−31 col.
D12	Columnas auxiliares de tiempo duplicadas	Descartar datetime_utc, hora_utc, date_local y dia_semana	Su información ya está en datetime_local, hour_local y day_of_week.	−4 col.
D13	En Uber surge_multiplier vale siempre 1	Restringir has_surge a Lyft	Para Uber la variable no informa nada: su modelo sería trivial.	−329.414 filas
D14	Lyft Shared nunca tiene recargo (0 de 51.233)	Excluir Shared del dataset de has_surge	Agregaría ceros garantizados: una regla trivial y más desbalance.	−51.201 filas
D15	price y surge_multiplier contienen la respuesta de has_surge	Excluir price y surge_multiplier; también cab_type (constante) y service_tier (= name en Lyft)	Evita el data leakage: el precio ya incluye el recargo.	−4 col.
D16	¿surge_multiplier como predictora de price?	Conservarla en dataset_price; en la Entrega 3 entrenar con y sin ella	Se conoce al cotizar (no es información futura) y es parte de la fórmula de la tarifa; la prueba con/sin cuantifica su aporte.	Sin cambios

Nota: D13 a D15 afectan solo al dataset de has_surge. El impacto en columnas se mide sobre la base de trabajo, que incluye las variables derivadas de la sección 8.

7. Integración de fuentes

7.1. Viajes y clima

Como el archivo llega unido, **separamos** las dos fuentes y las **volvimos a unir** con una clave diseñada por nosotros, para poder verificar la integración:

1. **Separación:** una tabla de viajes (una fila por cotización) y una de clima con 332 filas (una por hora).
2. **Validación de la clave:** en la tabla de clima, la hora es única (verificado).
3. **Unión** por hora con validación muchos-a-uno: si la clave no fuera única, la unión falla en lugar de duplicar filas en silencio. Resultado: 100% de los viajes con clima y los valores originales reproducidos exactamente.

¿Por qué por hora y no por zona? Porque el archivo conserva un solo registro de clima por hora: la información por zona se perdió en la unión de Kaggle y no se puede recuperar. Las 12 zonas están a pocos kilómetros entre sí, y el clima resultó irrelevante para ambos objetivos, así que la aproximación es razonable. La versión de dos archivos (*cab_rides.csv* y *weather.csv*) permitiría una unión por zona si en la Entrega 3 se quisiera profundizar.

7.2. Fuente externa: OpenStreetMap

Incorporamos las **coordenadas reales de las 12 zonas** desde OpenStreetMap (Nominatim), con un script reproducible y un control de que cada punto cae dentro de Boston. Con esta fuente: (1) detectamos 406 distancias imposibles entre zonas que están a por lo menos 0,33 millas en línea recta; (2) identificamos qué representan las coordenadas del dataset; y (3) creamos *straight_line_miles*, la distancia en línea recta entre origen y destino (correlación 0,84 con la distancia del viaje; el recorrido real es en mediana 1,57 veces más largo).

8. Selección e ingeniería de variables

Pasamos de **57 a 27 columnas**. La mayor reducción está en el clima: de 40 variables quedan 9. Las correlaciones se calcularon sobre la tabla de clima horaria (una fila por hora), donde hay 80 pares de variables con $|r| > 0{,}85$ (Figura 9).

Motivo	Columnas descartadas	Justificación
Redundantes con otra variable (4)	apparentTemperature, dewPoint, windGust, precipProbability	r = 0,95 (sensación térmica–temperatura), 0,94 (ráfagas–viento), 0,87 (rocío–temperatura); la probabilidad de lluvia es un pronóstico.
Agregados diarios (9)	temperatureHigh, temperatureLow, temperatureMin, temperatureMax, apparentTemperatureHigh, apparentTemperatureLow, apparentTemperatureMin, apparentTemperatureMax, precipIntensityMax	Tienen el mismo valor todo el día: no describen el momento del viaje.

Motivo	Columnas descartadas	Justificación
Marcas de tiempo diarias (12)	windGustTime, temperatureHighTime, temperatureLowTime, apparentTemperatureHighTime, apparentTemperatureLowTime, temperatureMinTime, temperatureMaxTime, apparentTemperatureMinTime, apparentTemperatureMaxTime, uvIndexTime, sunriseTime, sunsetTime	Correlación ≥ 0,998 con el tiempo. *sunriseTime* y *sunsetTime* se usan antes para crear *is_dark*.
Texto e íconos (2)	icon, long_summary	Repiten *short_summary* o resumen el día completo.
Sin relación plausible (4)	uvIndex, moonPhase, ozone, windBearing	Correlación casi nula con ambos objetivos y sin mecanismo que las vincule con la tarifa.

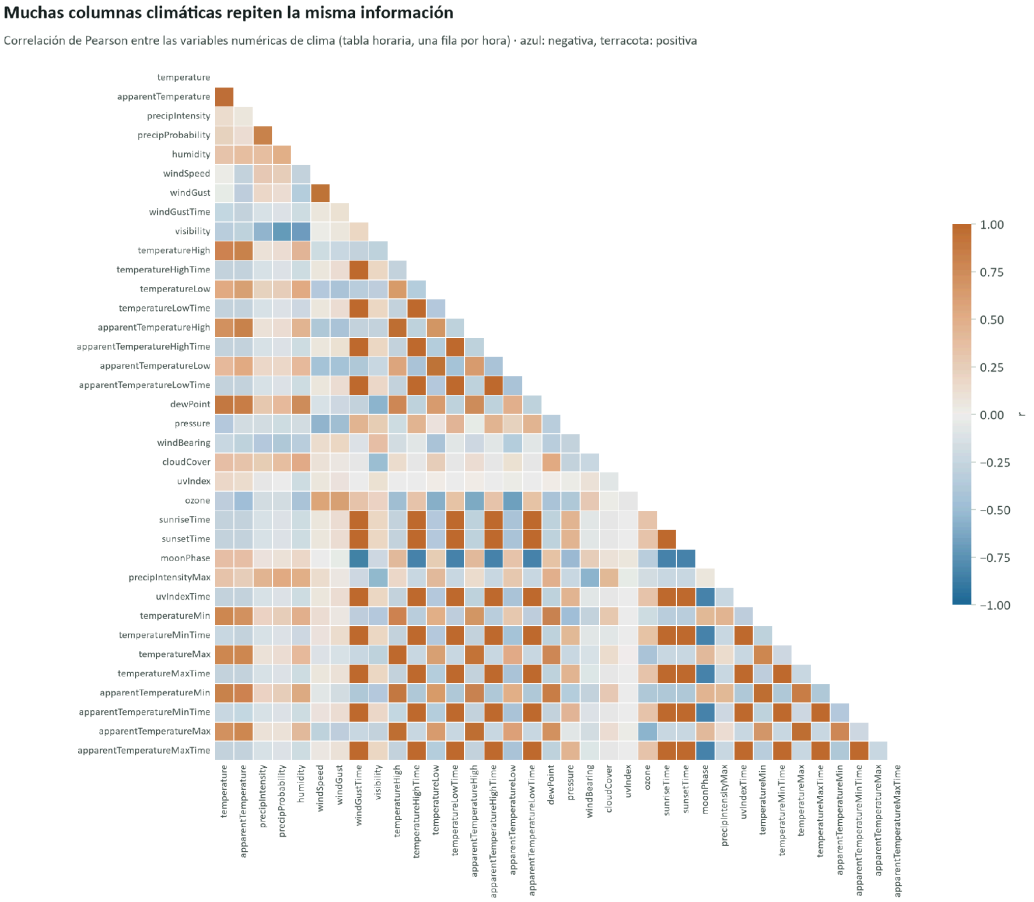


Figura 9. *Correlación entre las variables numéricas de clima (una fila por hora). Los bloques de color intenso son grupos de variables que repiten la misma información.*

Además se descartan *timezone* (constante), *visibility.1* (copia de *visibility*), *product_id* (equivale a *name*), *latitude*/*longitude* y las columnas de tiempo en UTC. *id* se conserva solo como identificador.

Variables nuevas: *hour_local*, *day_of_week*, *is_weekend*, *time_slot* (franja horaria), *is_rush_hour*, *is_dark*, *is_raining*, *service_tier* (nivel equivalente entre plataformas), *straight_line_miles* y el objetivo *has_surge*. El detalle de cada columna está en el diccionario de datos (*data/processed/diccionario_datos.md*).

9. Datasets resultantes

Archivo	Filas	Columnas	Objetivo y uso
Original (*rideshare_kaggle.csv*)	693.071	57	Sin modificar
rideshare_limpio_con_has_surge.csv	636.568	27	Dataset limpio general, con la nueva columna *has_surge*
dataset_price	636.568	26	*price* · Uber + Lyft · 23 predictoras
dataset_surge_lyft	255.953	23	*has_surge* · Lyft sin Shared · 20 predictoras · 8,19% positivos · sin *price* ni *surge_multiplier*

Se conserva el **91,85%** de las filas: se eliminaron 56.503, casi todas por la falta estructural de precio en Taxi. Los datasets de modelado se exportan también en Parquet (31,1 MB frente a 125,0 MB en CSV), que conserva los tipos de datos.

10. Plan de proyecto

10.1. Detalle del Sprint 2

Tarea	Responsable	Estado
Redefinición del alcance: segundo objetivo (has_surge)	Product Owner y equipo	Finalizada
Carga, descripción y comprensión de la estructura del dataset	Equipo de desarrollo	Finalizada
Análisis exploratorio de price y has_surge	Equipo de desarrollo	Finalizada
Evaluación de calidad en cinco dimensiones y tratamiento	Equipo de desarrollo	Finalizada
Integración de fuentes (clima y OpenStreetMap)	Equipo de desarrollo	Finalizada
Selección de variables y preparación de los datasets	Equipo de desarrollo	Finalizada
Redacción del informe y preparación de la defensa oral	Equipo de desarrollo	Finalizada

10.2. Próximos pasos: Sprint 3 (Modelado, 30/10)

- **price:** modelar *log(price)* con dos familias de algoritmos (una regresión lineal regularizada y un modelo de árboles, como Random Forest o Gradient Boosting). Métricas: MAE, RMSE y R^2. Entrenar con y sin *surge_multiplier*.
- **has_surge:** regresión logística y un modelo de árboles con pesos de clase. Como la clase positiva es el 8,2%, evaluamos con **PR-AUC, recall y F1**: la exactitud engaña, porque predecir siempre "sin recargo" ya acierta el 91,8%.
- **Validación agrupada por fecha** en ambos objetivos e interpretación de la importancia de las variables frente a las hipótesis H1–H6.

11. Referencias

Cátedra de Ciencia de Datos (2026). Trabajo Práctico Integral – Proyecto de Ciencia de Datos. Universidad Tecnológica Nacional, Facultad Regional Córdoba.

Cátedra de Ciencia de Datos (2026). EDA: el paso que puede cambiar por completo un proyecto de Data Science. Material de clase, UTN FRC.

Kaggle. Uber and Lyft Dataset Boston, MA. Recuperado de https://www.kaggle.com/datasets/brllrb/uber-and-lyft-dataset-boston-ma

OpenStreetMap contributors. Nominatim (servicio de geocodificación). Datos bajo licencia ODbL. Consultado el 01/10/2026 en https://nominatim.openstreetmap.org

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Kaufman, S., Rosset, S. y Perlich, C. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, 6(4).

Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.