¿Cuánto cuesta un viaje y cuándo hay recargo?

Entrega 3 · Modelado y análisis de resultados

Uber y Lyft en Boston · Grupo 11 · Ciencia de Datos 5K1 · UTN FRC · 30/10/2026

Álvaro Pérez · Juan Ignacio Cremona · Ignacio Gil · Federico Gon · Sofía Medina · Facundo Dagnino Dailly

---

Recorrido: 1 El problema · 2 Cómo trabajamos · 3 Qué modelos usamos y por qué · 4 Qué probamos y cómo elegimos · 5 Precio · 6 Recargo y accuracy · 7 Balanceo · 8 Modelo final · 9 Qué aprendimos · 10 Rutas · 11 Conclusiones

> *Entorno de ejecución* → *Ejecutar todo* (menos de 30 segundos). El código está oculto: se ve solo el resultado de cada celda.

1 · El problema

Pregunta del proyecto: ¿qué determina el precio de un viaje y qué tan bien lo podemos predecir?

	Objetivo 1	Objetivo 2
Pregunta	¿Cuánto cuesta el viaje?	¿Este viaje tiene recargo?
Variable	`price` (USD)	`has_surge` (sí / no)
Tipo	Regresión	Clasificación
Datos	Uber + Lyft · 636.568 cotizaciones	Lyft · 255.953 cotizaciones

Partimos del **dataset codificado** de la Entrega 2.

2 · Cómo trabajamos

1. **Separar por fecha.** Entrenamos con el pasado (25/11 al 14/12) y probamos con **4 días nuevos** (15 al 18/12). Si mezcláramos al azar, el modelo vería cotizaciones "gemelas" del mismo minuto y parecería mejor de lo que es.
2. **Probar varios modelos y configuraciones.** Cada modelo se probó con distintos parámetros.
3. **Elegir con validación**, usando solo fechas de entrenamiento: entrenamos con los primeros días y validamos con los siguientes. **La prueba final no se usa para elegir nada.**
4. **Evaluar** el modelo elegido en los 4 días de prueba e **interpretar** qué aprendió.

3 · Qué modelos usamos y por qué

Elegimos modelos de **menor a mayor complejidad**, para ver si la complejidad extra vale la pena:

Modelo	Para qué	Por qué lo elegimos
Regresión lineal (Ridge) / logística	Precio / recargo	Simple e interpretable: es la referencia. La logística es el modelo base de clasificación de la cátedra.
Árbol de decisión	Ambos	Da reglas fáciles de explicar ("si sale de tal zona y la distancia es menor a...") y capta escalones.
Random forest	Ambos	Muchos árboles promediados: más estable que un árbol solo.
Gradient boosting	Recargo	Árboles en serie, cada uno corrige al anterior (la idea de AdaBoost). Suele ser el más preciso.
K-Means	Rutas	Agrupa rutas parecidas sin variable objetivo (no supervisado).

4 · Qué probamos y cómo elegimos

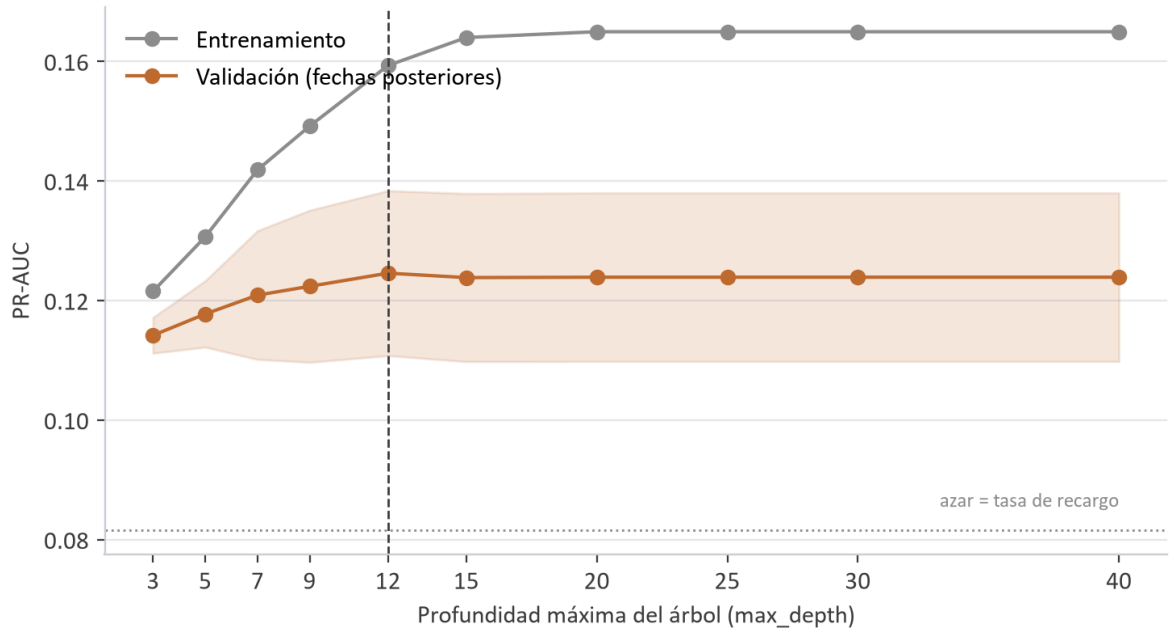
Cada modelo se probó con **varias configuraciones** (por ejemplo, árboles más o menos profundos). Para cada uno mostramos tres pruebas: una **más simple**, una **más compleja** y la **elegida**, que es la que mejor rindió en validación.

Modelo	Más simple	Elegida	Más compleja	Configuración elegida
Regresión logística	= elegida	0,120	0,112	C=0.0001
Árbol de decisión	0,114	0,125	0,103	criterion=gini · max_depth=12 · min_samples_leaf=500
Random forest	0,125	0,126	= elegida	max_depth=16 · min_samples_leaf=10
Gradient boosting	= elegida	0,136	0,133	learning_rate=0.05 · max_leaf_nodes=15

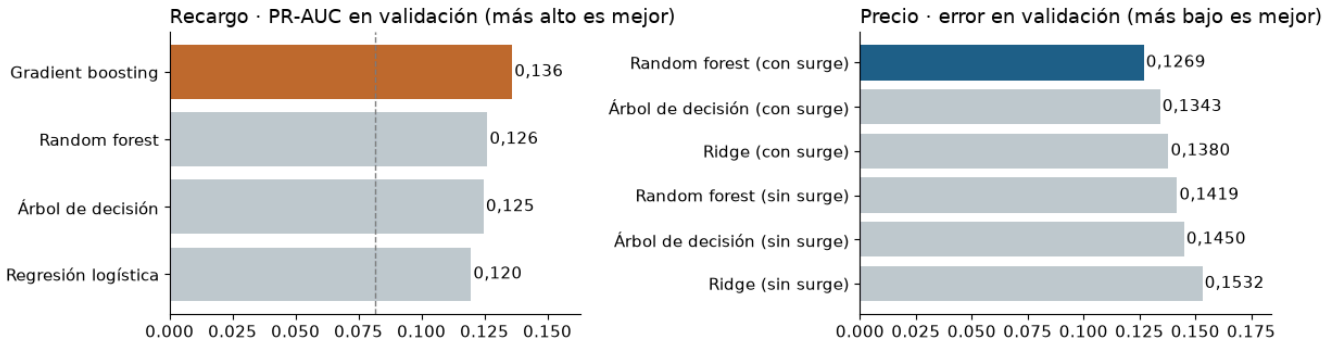
Puntaje: **PR-AUC en validación** (el azar da 0,08). La configuración más compleja rinde muy bien en entrenamiento pero no en días nuevos: **memoriza**.

A mayor profundidad, entrenamiento y validación se separan: el árbol empieza a memorizar

PR-AUC en entrenamiento y validación temporal en orden (4 folds) · pesos de clase (balanced) · min_samples_leaf = 500, criterio = gini



Más profundidad mejora en entrenamiento pero **no en días nuevos**: el árbol empieza a memorizar. Elegimos el punto donde la validación deja de mejorar.



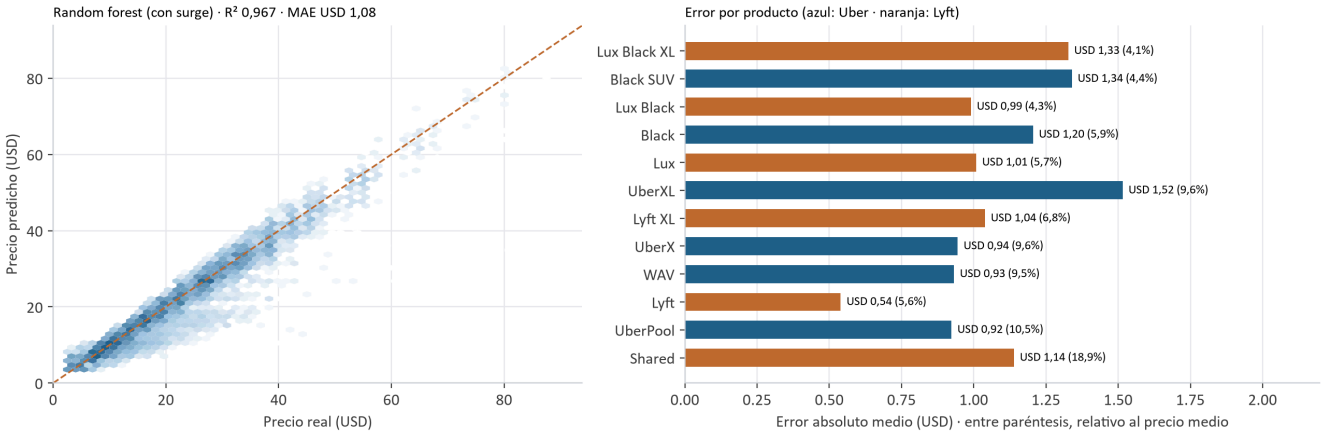
- **Recargo:** gana **gradient boosting**, aunque los cuatro quedan cerca → el límite no es el algoritmo sino la información disponible.
- **Precio:** gana **random forest con surge**. Los árboles superan al modelo lineal porque la tarifa crece por escalones.

5 · Objetivo 1 · ¿Cuánto cuesta el viaje?

Modelo	Variante	Error medio	Viajes con error ≤ 10%	R^2
Línea base (solo el producto)	-	USD 3,04	34%	0,758
Ridge	sin surge	USD 1,62	62%	0,910
Ridge	con surge	USD 1,39	65%	0,951
Árbol de decisión	sin surge	USD 1,35	71%	0,927
Árbol de decisión	con surge	USD 1,09	74%	0,966
Random forest	sin surge	USD 1,32	72%	0,928
Random forest	con surge	USD 1,08	75%	0,967

El precio se predice con un error típico de pocos dólares

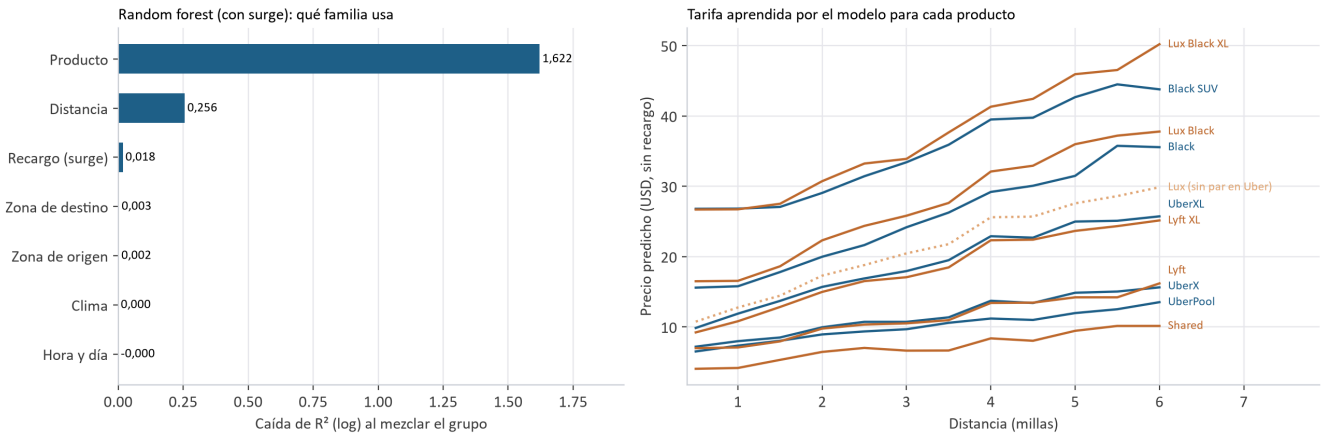
Regresión sobre log(price) · período de prueba 15 al 18/12/2018 · Uber + Lyft



- El modelo elegido se equivoca en promedio **USD 1,08** y acierta el precio (con error ≤ 10%) en el **75%** de los viajes.
- Supera a la regresión lineal (USD 1,39 de error): la tarifa sube **por escalones**.
- Sin `surge_multiplier` el precio ya es predecible (R^2 = 0,928); con él, el error baja un 18%.

El producto y la distancia explican el precio; el momento y el clima casi no aportan

Importancia por permutación en una muestra del período de prueba · curvas: mediana de la predicción variando solo producto y distancia



- **El producto y la distancia explican el precio** (H1). La hora y el clima no aportan.

- **Uber vs Lyft (H2):** Lyft es más barato en los económicos (Shared –29%) y más caro en los Black (+8%).

6 · Objetivo 2 · ¿Tiene recargo? El problema de la accuracy

Solo **8,2%** de las cotizaciones tiene recargo (1 de cada 12).

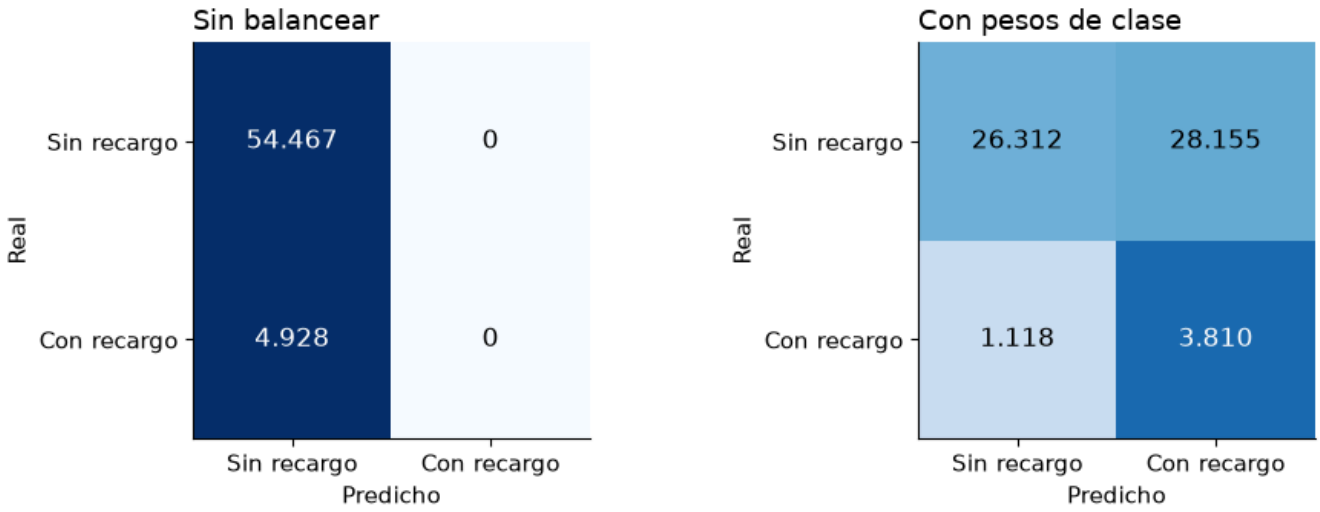
La **accuracy** es el % de predicciones correctas. Un "modelo" que dice **siempre "sin recargo"** tiene **91,7% de accuracy**... y no detecta ningún recargo.

Por eso miramos la accuracy **junto con**:

- **Accuracy balanceada:** promedio del acierto en cada clase (50% = azar).
- **Recall:** qué % de los recargos detecta.
- **Precisión:** de las alertas, cuántas son recargos reales.

Demostración en vivo: el mismo árbol, sin balancear y balanceado

Árbol	Accuracy	Accuracy balanceada	Recall (recargos detectados)	Precisión
Sin balancear	91,7%	50,0%	0,0%	0,0%
Con pesos de clase	50,7%	62,8%	77,3%	11,9%



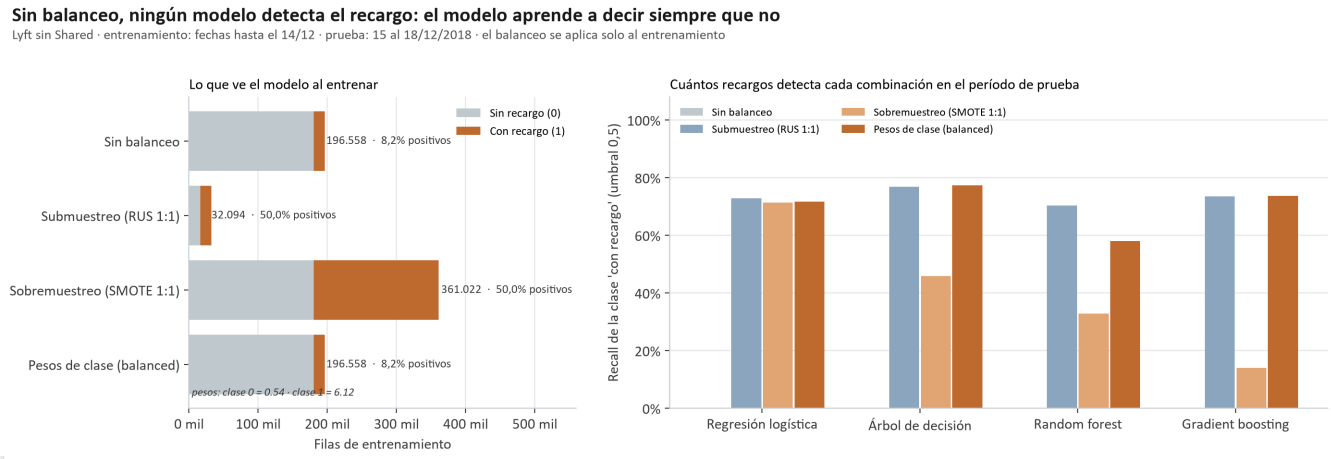
Conclusión: sin balancear, la accuracy es altísima pero el modelo casi nunca avisa de un recargo. Balanceando, la accuracy baja pero **la accuracy balanceada y el recall suben**: el modelo empieza a detectar recargos.

7 · Balanceo de clases: cuatro técnicas

El balanceo se aplica **solo al entrenamiento**; la prueba siempre mantiene la proporción real.

Técnica	Qué hace	Filas para entrenar	% con recargo
Sin balanceo	Datos tal cual	196.558	8,2%
Submuestreo	Descarta cotizaciones sin recargo	32.094	50%
SMOTE	Inventa recargos "sintéticos"	361.022	50%
Pesos de clase	No cambia los datos: equivocarse en un recargo "cuesta" 6,1 veces más	196.558	8,2%

Los datasets balanceados están en `4_Datasets/datasets balanceados/`.

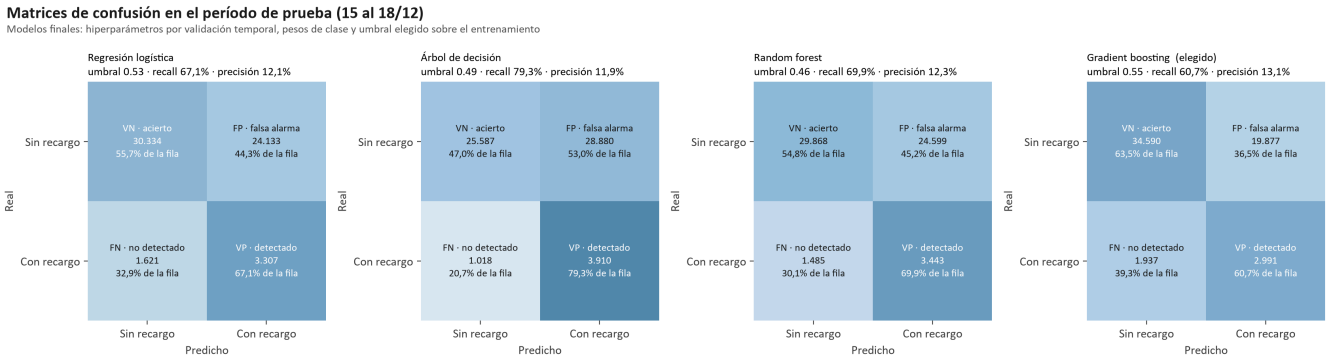


- **Sin balanceo** los modelos casi no detectan recargos.
- **Submuestreo** funciona, pero tira el 91% de los datos.
- **SMOTE** inventa cotizaciones imposibles (por ejemplo "0,4 de Back Bay") y no ayuda.
- **Elegimos pesos de clase por validación:** fue la de mejor resultado sin mirar la prueba, y además usa todos los datos reales.

8 · Modelo final: gradient boosting

Con pesos de clase y un **umbral de decisión** elegido en validación (no en la prueba).

Modelo	Accuracy	Accuracy balanceada	Recall	Precisión	PR-AUC
Gradient boosting ★	63,3%	62,1%	60,7%	13,1%	0,140
Regresión logística	56,6%	61,4%	67,1%	12,1%	0,121
Árbol de decisión	49,7%	63,2%	79,3%	11,9%	0,138
Random forest	56,1%	62,4%	69,9%	12,3%	0,141



Cómo leer la matriz de confusión (gradient boosting)

	Predijo sin recargo	Predijo con recargo
Real: sin recargo	**VN = 34.590** · acierto	**FP = 19.877** · falsa alarma
Real: con recargo	**FN = 1.937** · recargo no detectado	**VP = 2.991** · recargo detectado

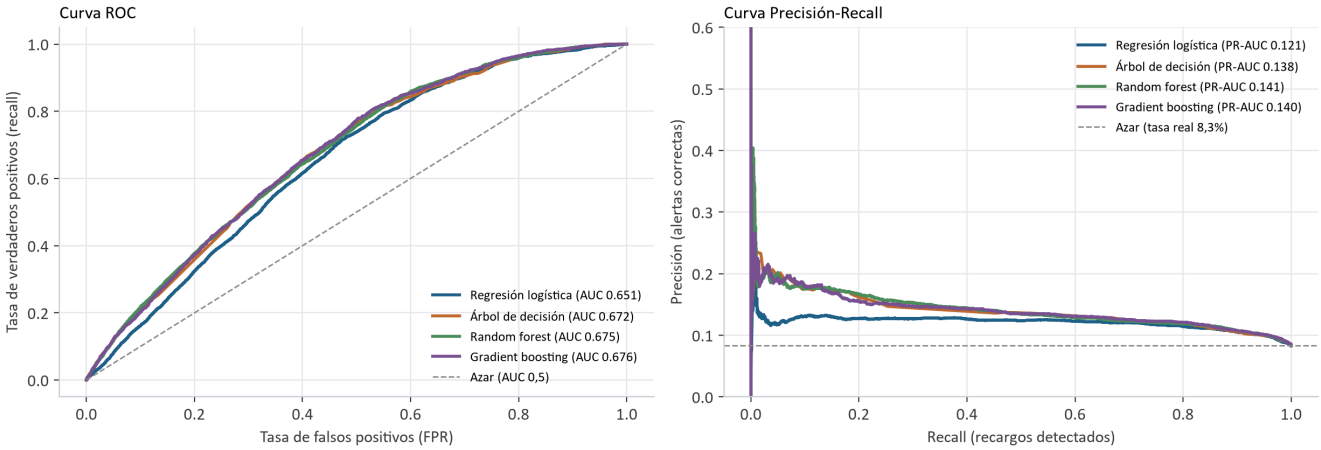
- **Falso positivo (FP):** el modelo avisa un recargo que no ocurre → el pasajero compara sin necesidad.
- **Falso negativo (FN):** hay recargo y el modelo no avisa → el pasajero **paga ~46% más** sin saberlo. **Es el error más caro**, por eso priorizamos detectar recargos.
- De la matriz salen las métricas: **accuracy** = (VP + VN) / total = 63,3% · **precisión** = VP / (VP + FP) = 13,1% · **recall** = VP / (VP + FN) = 60,7%.

Cómo leer el resultado del modelo elegido:

- **Accuracy 63,3%**, menor que el 91,7% de "decir siempre que no", porque ahora el modelo **sí avisa** recargos y a veces se equivoca.
- Acierta el **63,5%** de los viajes sin recargo y el **60,7%** de los con recargo → **accuracy balanceada 62,1%** (azar = 50%).
- De cada 100 alertas, **13** son recargos reales (el azar acierta 8).

Los modelos ordenan el riesgo mejor que el azar, pero con poco margen

Período de prueba · con 8% de positivos, la curva Precisión-Recall es más exigente que la ROC

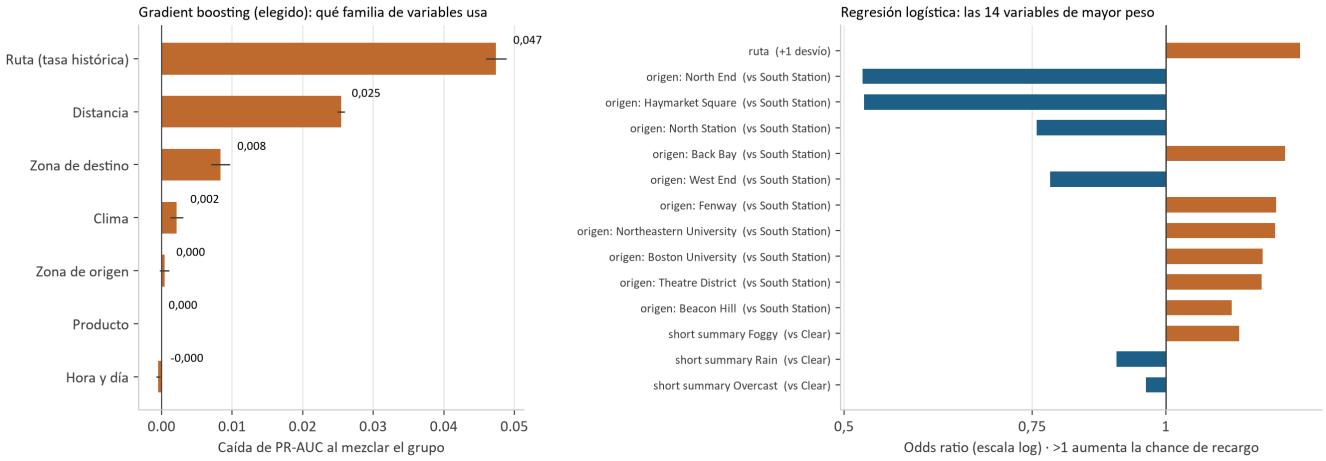


Todos los modelos están por encima del azar, pero con poco margen: **el recargo es difícil de anticipar** con estos datos.

9 · ¿Qué aprendieron los modelos?

El recargo depende sobre todo del lugar (ruta y zona de origen); la hora y el clima casi no aportan

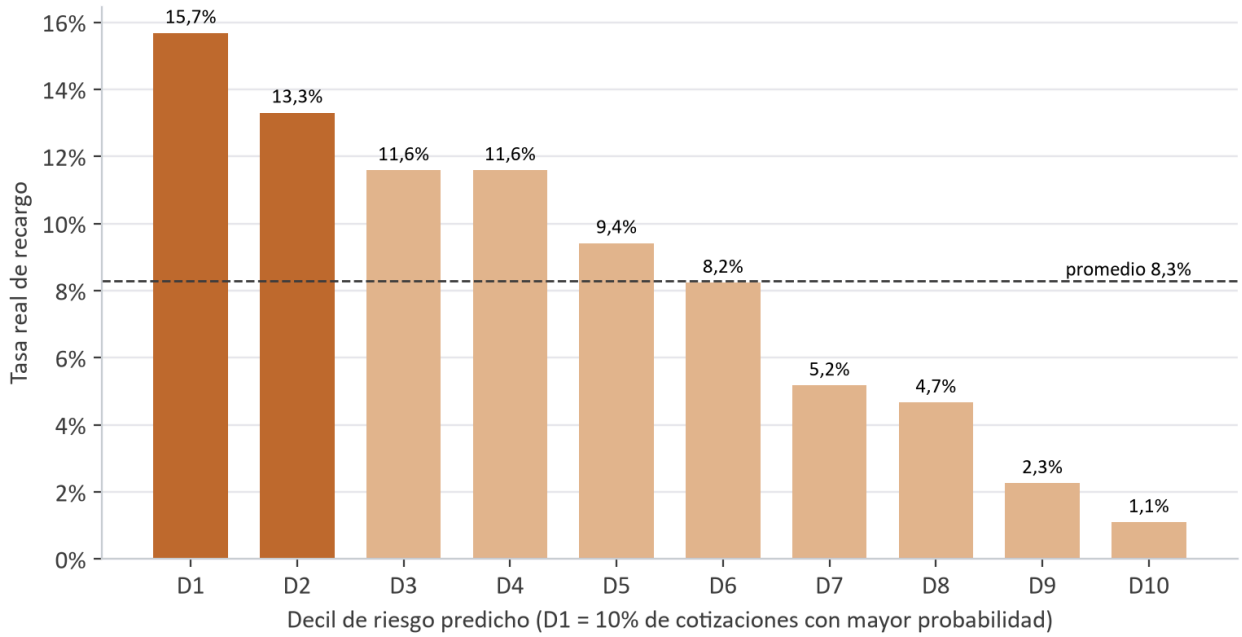
Importancia por permutación en el período de prueba (3 repeticiones; el modelo ya está entrenado) · odds ratio contra South Station, la zona con la tasa promedio



- **El lugar es lo que más importa:** la ruta y la zona de origen.
- Comparado con South Station (zona promedio), salir de **Back Bay** multiplica la chance de recargo por 1,3; salir de **North End**, por 0,5.
- **La hora y el clima casi no aportan.**

El 20% de mayor riesgo concentra el 34,9% de los recargos

Gradient boosting con pesos de clase · período de prueba · tasa real de recargo en cada decil de probabilidad predicha



El modelo no adivina viaje por viaje, pero **ordena el riesgo**: el 20% de cotizaciones de mayor riesgo concentra el **35%** de los recargos.

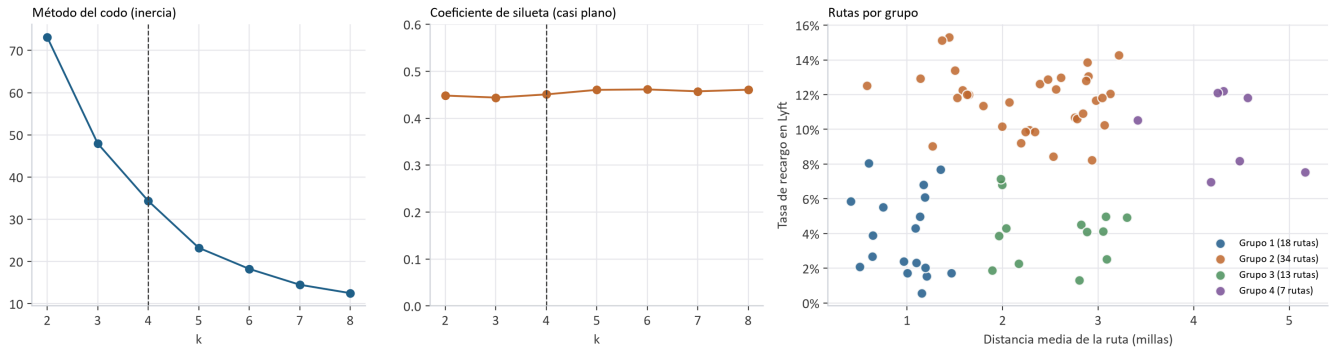
¿Por qué validar por fecha?

Si hubiéramos separado los datos al azar, los modelos parecerían **hasta un 87% mejores**. Es una mejora falsa: reconocen cotizaciones del mismo minuto que vieron al entrenar.

10 · Perfiles de rutas (K-Means)

Agrupamos las 72 rutas por **distancia** y **tasa de recargo**. La silueta es pareja para todos los k (no hay grupos naturales muy marcados), así que elegimos **k = 4** porque es fácil de interpretar.

Las 72 rutas en 4 perfiles: largo del viaje × nivel de recargo
K-Means sobre distancia media y tasa de recargo (estandarizadas) · la silueta es pareja para todo k: se eligió k = 4 por interpretabilidad



Grupo	Rutas	Distancia media	Precio por milla	Recargo	Ejemplo
1	18	1,0 mi	USD 8,81	3,9%	South Station → Financial District
2	34	2,3 mi	USD 4,62	11,7%	Back Bay → Boston University
3	13	2,5 mi	USD 4,09	4,1%	South Station → West End
4	7	4,3 mi	USD 3,02	9,9%	Fenway → Financial District

- Las rutas **cortas** son las más caras por milla por la tarifa base (H4). Ejemplo: Financial District → South Station, USD 17,95 por milla.
- El recargo alto aparece en rutas de **distintas distancias**, siempre saliendo del oeste (Back Bay, Fenway, universidades). Coincide con el modelo de clasificación.

11 · Conclusiones

Hipótesis	Resultado
H1 · Producto y distancia definen el precio	✓ Confirmada
H2 · Uber y Lyft difieren según el nivel	✓ Confirmada
H3 · Hay patrones horarios	✘ No se confirma
H4 · Hay rutas más caras por milla	✓ Confirmada (las cortas)
H5 · El mal clima encarece	✘ Rechazada
H6 · Hay segmentos de viajes	≈ Parcial

Respuesta al problema

1. **El precio es predecible:** con el producto, la distancia y el multiplicador se estima con un error de ~USD 1,08.
2. **El recargo es lo difícil de anticipar:** depende del **lugar**, no de la hora ni del clima. Lo demás depende de la oferta y la demanda en tiempo real, que no están en los datos.
3. **Valor práctico:** si salís de Back Bay, Fenway o las universidades, conviene **comparar con Uber** o caminar a una zona vecina.

Próximo paso (Entrega 4): contar esta historia para el pasajero, el conductor y la plataforma.

Anexo · Dónde está cada cosa

Carpeta	Contenido
`1_Informe/`	Informe completo, con todos los detalles técnicos
`3_Codigo/`	`modelado_entrega3.py` : reproduce todo
`4_Datasets/`	Datasets de modelado y balanceados
`5_Graficos/` y `6_Resultados/`	Figuras y tablas