Open in Colab

¿Cuánto cuesta un viaje y cuándo hay recargo?

Entrega 3 · Modelado y análisis de resultados

Uber y Lyft en Boston · Grupo 11 · Ciencia de Datos 5K1 · UTN FRC · 30/10/2026

Álvaro Pérez · Juan Ignacio Cremona · Ignacio Gil · Federico Gon · Sofía Medina · Facundo Dagnino Dailly

---

Recorrido: 1 El problema · 2 Decisiones y por qué · 3 Qué mejoramos y cómo · 4 Modelos y pruebas · 5 Precio · 6 Recargo y accuracy · 7 Balanceo · 8 Modelo final · 9 Matriz de beneficio · 10 Curva ROC y AUC · 11 Qué aprendió el modelo · 12 Validación · 13 Familias de tarifa · 14 Conclusiones

> *Entorno de ejecución → Ejecutar todo* (menos de un minuto). El código está oculto: se ve solo el resultado de cada celda.

```
Listo: resultados cargados
```

1 · El problema

Pregunta del proyecto: ¿qué determina el precio de un viaje y qué tan bien lo podemos predecir?

	Objetivo 1	Objetivo 2
Pregunta	¿Cuánto cuesta el viaje?	¿Esta cotización tiene recargo?
Variable	`price` (USD)	`has_surge` (sí / no)
Tipo	Regresión	Clasificación
Datos	Uber + Lyft · 636.568 cotizaciones	Lyft sin Shared · 255.953 cotizaciones (8,2% con recargo)
Variables predictoras	Producto, distancia, zonas, hora, día y clima (con y sin `surge_multiplier`)	Las mismas + la tasa histórica de recargo de la ruta · **sin** `price` ni `surge_multiplier` (fuga de datos)

Partimos del **dataset codificado** de la Entrega 2.

2 · Las decisiones que tomamos y por qué

Decisión	Por qué
Separar por fecha: entrenamos del 25/11 al 14/12 y probamos con 4 días nuevos (15 al 18/12)	Cotizaciones del mismo minuto y ruta comparten el recargo. Si se mezclan, el modelo reconoce "gemelas" y parece mejor de lo que es.
Validación cruzada temporal en orden (4 folds) para elegir todo	Cada fold entrena con fechas anteriores y valida con las siguientes. La prueba final no se usa para elegir nada.
Comparamos con una validación cruzada mezclada (5 folds estratificados)	Para medir cuánto infla los resultados mezclar las fechas (sección 12).
El balanceo se aplica solo al entrenamiento de cada fold	La validación y la prueba mantienen la proporción real (8% con recargo): queremos saber cómo funciona en el mundo real.
Grillas de hiperparámetros extendidas hasta que el valor elegido quedara adentro	Si el mejor valor está en el borde, el óptimo podría estar más allá y el parámetro no queda justificado.
El umbral de decisión se elige con una matriz de beneficio	Pone en dólares lo que vale cada acierto y cada error (sección 9).
Intervalos de confianza del 95% por bootstrap de horas	Para saber qué tan seguros son los números (las cotizaciones de una misma hora no son independientes).
Modelamos log(price)	El precio tiene una cola de viajes caros; en log los errores son relativos.

3 · Qué mejoramos respecto de la versión preliminar y cómo

Antes	Ahora	Cómo lo logramos
Partición al azar (métricas infladas)	Partición por fecha + validación cruzada temporal	Bloques de fechas consecutivos; se valida siempre con días posteriores
Hiperparámetros fijos, sin justificar	Búsqueda en grilla para cada modelo y técnica	`GridSearchCV` con la validación temporal; grillas extendidas hasta que el óptimo quedara adentro
Umbral fijo de 0,5	Umbral elegido con la matriz de beneficio	Se maximiza el beneficio en validación y se aplica tal cual a la prueba
Accuracy sin referencia	Accuracy siempre contra líneas base	"Siempre sin recargo", "siempre con recargo", azar y la tasa de la zona de origen
Sin interpretación	Importancia de variables, odds ratio, árbol y deciles	Odds ratio con regularización débil para no encogerlos
Números sin margen de error	Intervalos de confianza del 95%	Bootstrap de bloques por hora
Clasificación multiclase circular	K-Means de los 12 productos	Codo y silueta (k = 3)
Se suponía que balancear era necesario	Lo comprobamos	Comparamos sin balanceo con el umbral ajustado (sección 7)

4 · Qué modelos usamos y por qué

Elegimos modelos de **menor a mayor complejidad**, para ver si la complejidad extra vale la pena:

Modelo	Para qué	Por qué lo elegimos
Regresión lineal (Ridge) / logística	Precio / recargo	Simples e interpretables: son la referencia. La logística es el modelo base de clasificación de la cátedra.
Árbol de decisión	Ambos	Da reglas fáciles de explicar ("si sale de tal zona y la distancia es menor a...") y capta escalones.
Random forest	Ambos	Muchos árboles promediados: más estable que un árbol solo.
Gradient boosting	Recargo	Árboles en serie, cada uno corrige al anterior (la idea de AdaBoost).
K-Means	Productos	Agrupa los productos según su tarifa, sin variable objetivo (no supervisado).

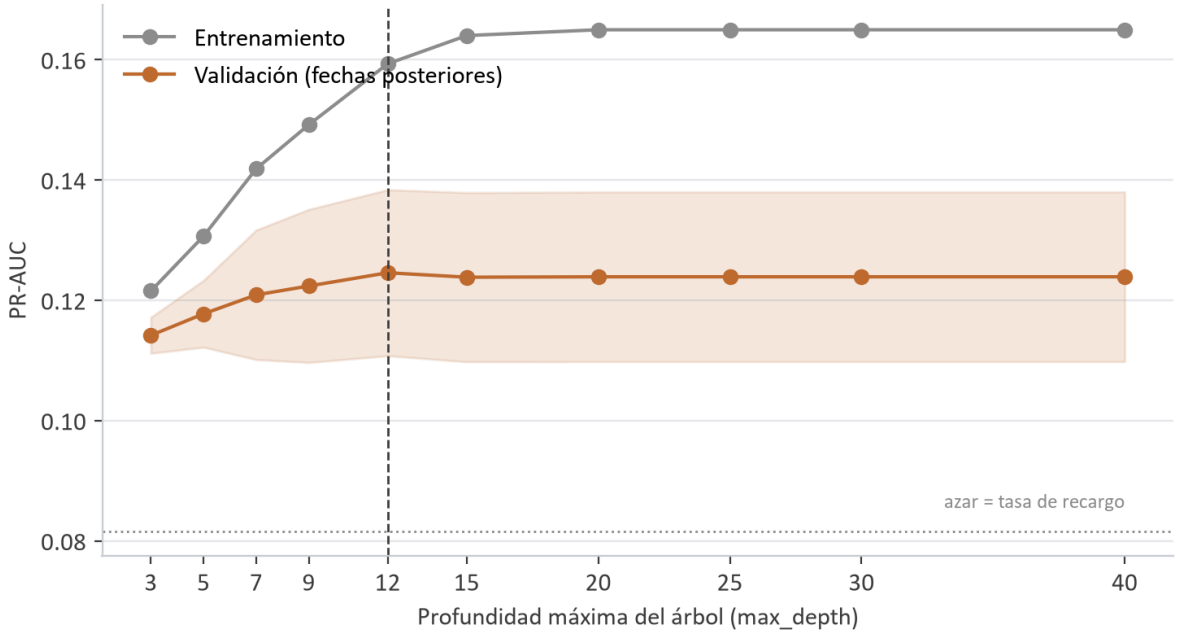
Cada modelo se probó con **varias configuraciones**. Mostramos la **más simple**, la **elegida** (mejor en validación) y la **más compleja**.

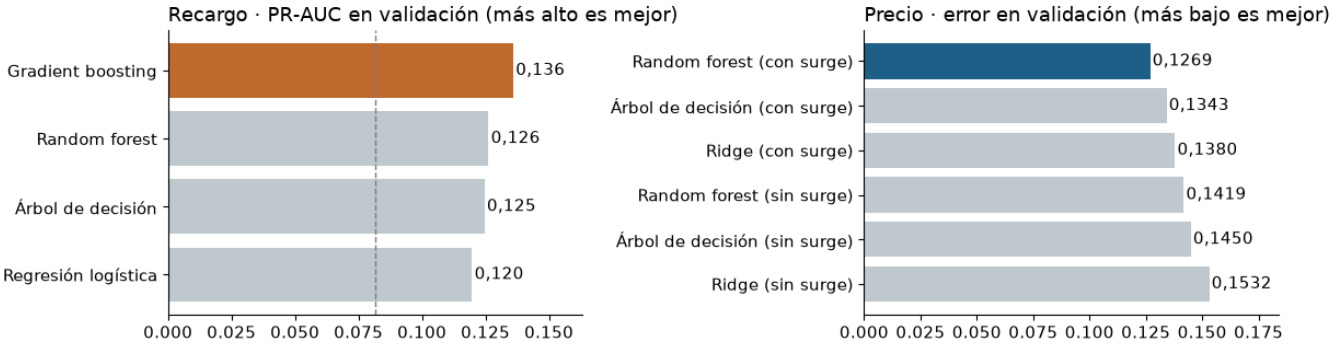
Modelo	Más simple	Elegida	Más compleja	Configuración elegida
Regresión logística	0,119 (entren. 0,130)	0,120 (entren. 0,131)	0,112 (entren. 0,132)	C=0.00003
Árbol de decisión	0,115 (entren. 0,123)	0,125 (entren. 0,159)	0,103 (entren. 0,427)	criterion=gini · max_depth=12 · min_samples_leaf=500
Random forest	0,124 (entren. 0,187)	0,126 (entren. 0,510)	0,124 (entren. 0,627)	max_depth=24 · min_samples_leaf=10
Gradient boosting	0,130 (entren. 0,159)	0,136 (entren. 0,240)	0,132 (entren. 0,424)	learning_rate=0.05 · max_leaf_nodes=15

La configuración más compleja rinde mucho mejor en **entrenamiento** que en **validación**: memoriza días puntuales. Por eso se elige por validación, nunca por entrenamiento.

A mayor profundidad, entrenamiento y validación se separan: el árbol empieza a memorizar

PR-AUC en entrenamiento y validación temporal en orden (4 folds) · pesos de clase (balanced) · min_samples_leaf = 500, criterio = gini





- **Recargo:** gana **gradient boosting**, aunque los cuatro quedan cerca → el límite no es el algoritmo sino la información disponible.
- **Precio:** gana **random forest (con surge)**. Los árboles superan al modelo lineal porque la tarifa crece por escalones.

5 · Objetivo 1 · ¿Cuánto cuesta el viaje?

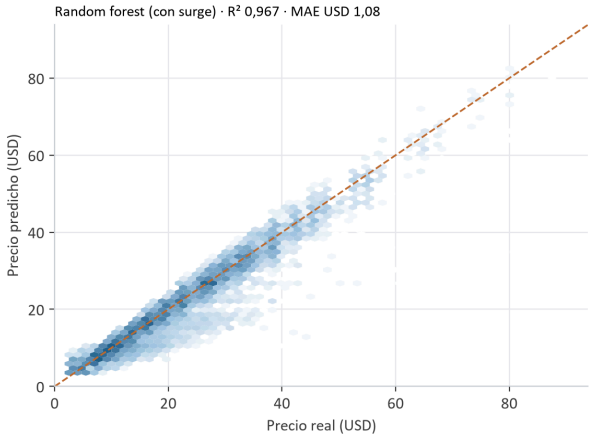
Modelo	Variante	Error medio	Viajes con error ≤ 10%	R^2
Línea base (solo el producto)	-	USD 3,04	34%	0,758
Ridge	sin surge	USD 1,62	62%	0,910
Ridge	con surge	USD 1,39	65%	0,951
Árbol de decisión	sin surge	USD 1,35	71%	0,927
Árbol de decisión	con surge	USD 1,09	74%	0,966
Random forest	sin surge	USD 1,32	72%	0,928
Random forest	con surge	USD 1,08	75%	0,967

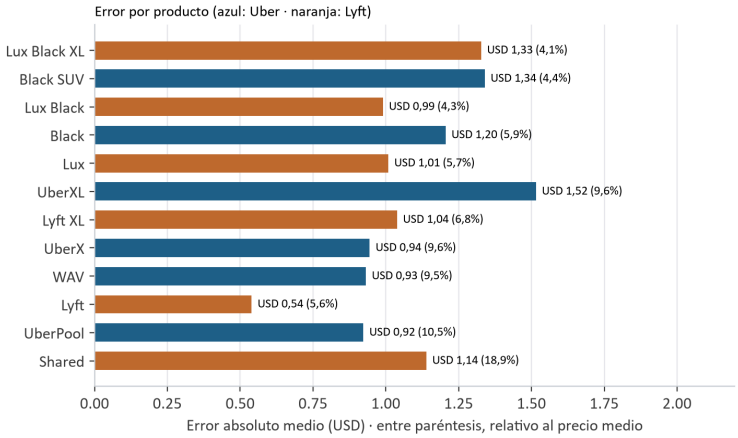
Con y sin `surge_multiplier`: el modelo elegido (random forest (con surge)) se equivoca en promedio **USD 1,08** (R^2 = 0,967); sin el multiplicador, **USD 1,32** (R^2 = 0,928). El multiplicador ayuda, pero el precio ya es predecible sin él.

Certeza (IC 95%): error medio USD 1,08 (IC 95%: USD 1,07 a USD 1,09) · R^2 0,967 (IC 95%: 0,966 a 0,968) · viajes con error ≤ 10%: 75,0% (IC 95%: 74,7% a 75,2%).

El precio se predice con un error típico de pocos dólares

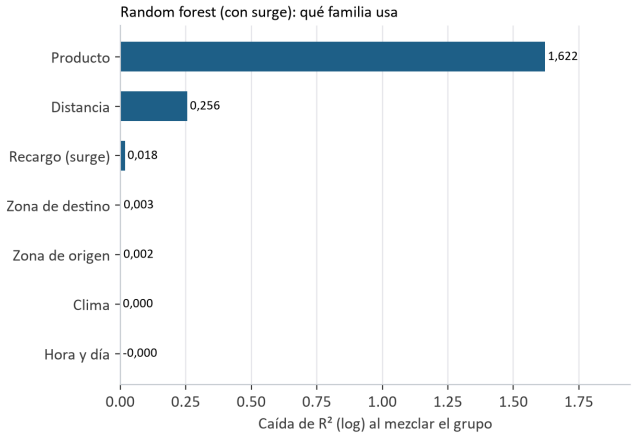
Regresión sobre log(price) · período de prueba 15 al 18/12/2018 · Uber + Lyft

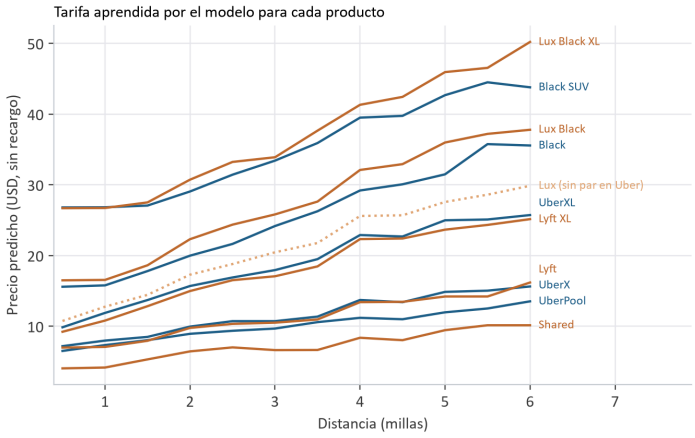




El producto y la distancia explican el precio; el momento y el clima casi no aportan

Importancia por permutación en una muestra del período de prueba · curvas: mediana de la predicción variando solo producto y distancia





- **El producto y la distancia explican el precio** (H1). La hora y el clima no aportan.
- **Uber vs Lyft (H2):** Lyft es más barato en los económicos (Shared -29%) y más caro en los Black (+8%).

6 · Objetivo 2 · ¿Tiene recargo? El problema de la accuracy

Solo **8,2%** de las cotizaciones tiene recargo (1 de cada 12).

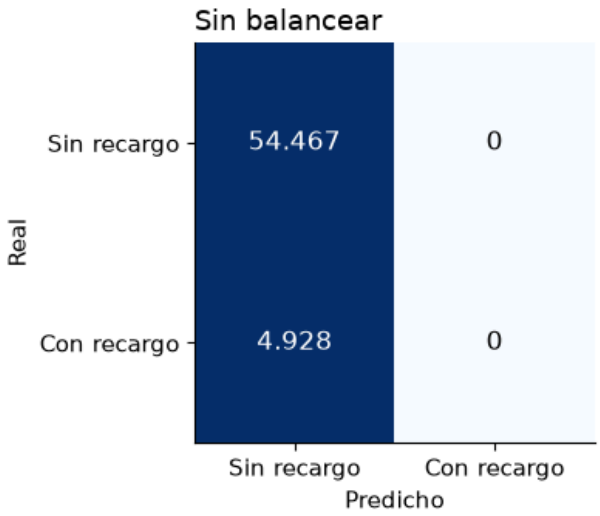
La **accuracy** es el % de predicciones correctas. Un "modelo" que dice **siempre "sin recargo"** tiene **91,7% de accuracy**... y no detecta ningún recargo. Por eso la accuracy se lee **siempre contra estas referencias**:

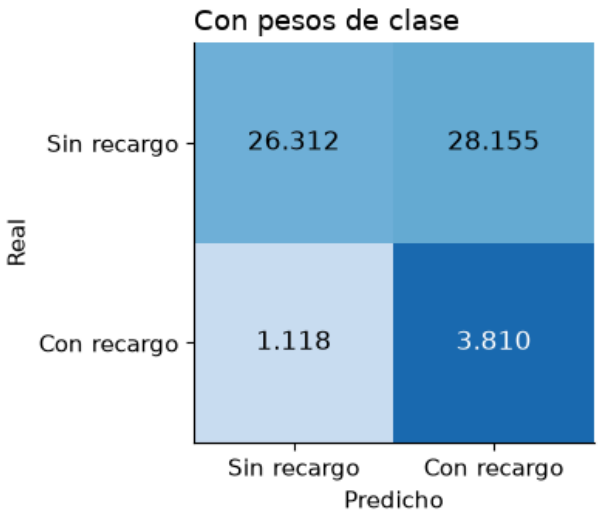
Referencia	Accuracy	Accuracy balanceada	Recall	Precisión	PR-AUC
Siempre 'sin recargo'	91,7%	50,0%	0,0%	0,0%	0,083
Siempre 'con recargo'	8,3%	50,0%	100,0%	8,3%	0,083
Azar con la tasa real	85,0%	50,1%	8,2%	8,4%	0,083
Tasa histórica de la zona de origen	66,0%	58,7%	50,0%	12,2%	0,118

- **Accuracy balanceada:** promedio del acierto en cada clase (50% = azar).
- **Recall:** qué % de los recargos detecta. **Precisión:** de las alertas, cuántas son recargos reales.
- La referencia más exigente es la **tasa de la zona de origen**, sin ningún modelo: ya logra PR-AUC 0,118.

Demostración en vivo: el mismo árbol, sin balancear y balanceado (umbral 0,5)

Árbol	Accuracy	Accuracy balanceada	Recall (recargos detectados)	Precisión
Sin balancear	91,7%	50,0%	0,0%	0,0%
Con pesos de clase	50,7%	62,8%	77,3%	11,9%



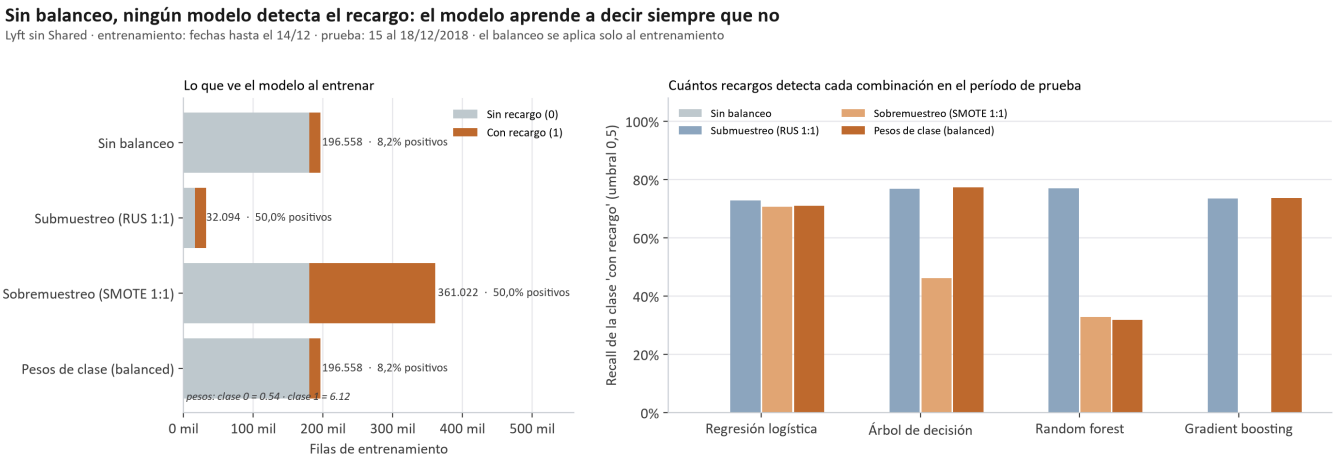


Conclusión: con el umbral estándar de 0,5, el árbol sin balancear casi nunca avisa de un recargo: accuracy altísima, recall casi nulo. Balanceando, la accuracy baja pero **la accuracy balanceada y el recall suben**. Ojo: esto pasa con el umbral 0,5. En la sección 7 vemos qué pasa cuando el umbral también se ajusta.

7 · Balanceo de clases: cuatro técnicas

El balanceo **no cambia la realidad**: cambia cómo aprende el modelo, para que no ignore los recargos. Se aplica **solo al entrenamiento**; la validación y la prueba mantienen la proporción real.

Técnica	Qué hace	Filas para entrenar	% con recargo
Sin balanceo	Datos tal cual	196.558	8,2%
Submuestreo	Descarta cotizaciones sin recargo	32.094	50%
SMOTE	Inventa recargos "sintéticos"	361.022	50%
Pesos de clase	No cambia los datos: equivocarse en un recargo "cuesta" 11 veces más	196.558	8,2%



Modelo	Técnica	Umbral	Recall	Precisión	PR-AUC	Beneficio / 1.000
Regresión logística	Sin balanceo	0,10	64,5%	12,1%	0,121	USD 26
Regresión logística	Pesos de clase	0,54	63,5%	12,2%	0,121	USD 29
Árbol de decisión	Sin balanceo	0,14	28,4%	15,2%	0,139	USD 51
Árbol de decisión	Pesos de clase	0,63	21,1%	16,0%	0,138	USD 43
Random forest	Sin balanceo	0,12	42,8%	14,2%	0,138	USD 61
Random forest	Pesos de clase	0,44	53,3%	13,3%	0,142	USD 55
Gradient boosting	Sin balanceo	0,11	49,6%	13,5%	0,144	USD 54
Gradient boosting	Pesos de clase	0,57	51,4%	13,5%	0,140	USD 56

- **Balancear no mejora el ranking, mueve el umbral:** el PR-AUC casi no cambia. Sin balanceo el modelo también detecta recargos si el umbral se baja (por eso sin balanceo los umbrales son tan chicos).
- En validación, la mejor técnica fue: regresión logística, sin balanceo; árbol de decisión, sin balanceo; random forest, sin balanceo; gradient boosting, pesos de clase.
- **Elegimos pesos de clase** porque formó el mejor par en validación (gradient boosting + pesos de clase) y usa todos los datos reales.
- **SMOTE** inventa cotizaciones imposibles ("0,4 de Back Bay") y no ayuda. **Submuestreo** tira el 91% de los datos.

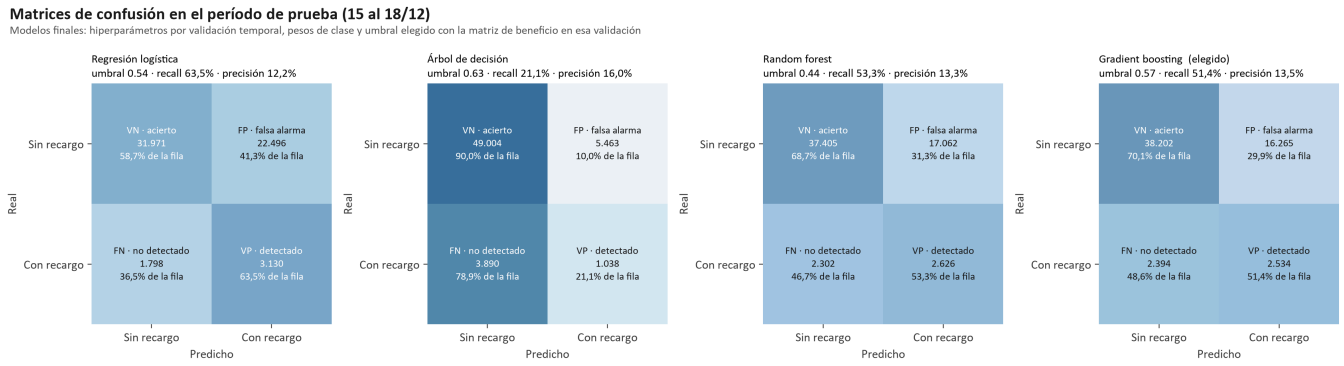
8 · Modelo final y su accuracy

Pesos de clase y un **umbral de decisión** elegido con la matriz de beneficio en validación (no en la prueba).

Modelo	Umbral	Accuracy	Accuracy balanceada	Recall	Precisión	ROC-AUC	PR-AUC
Gradient boosting ★	0,57	68,6%	60,8%	51,4%	13,5%	0,676	0,140
Regresión logística	0,54	59,1%	61,1%	63,5%	12,2%	0,650	0,121
Árbol de decisión	0,63	84,3%	55,5%	21,1%	16,0%	0,672	0,138
Random forest	0,44	67,4%	61,0%	53,3%	13,3%	0,675	0,142
Referencia: siempre 'sin recargo'	–	91,7%	50,0%	0,0%	0,0%	0,500	0,083
Referencia: tasa histórica de la zona de origen	–	66,0%	58,7%	50,0%	12,2%	0,649	0,118

Métrica	Valor	IC 95%
Accuracy	68,6%	67,3% a 69,8%
Accuracy balanceada	60,8%	59,4% a 62,1%
Precisión	13,5%	12,7% a 14,3%
Recall	51,4%	48,4% a 54,5%
ROC-AUC	0,676	0,663 a 0,689
PR-AUC	0,140	0,132 a 0,150
Ventaja de PR-AUC sobre la tasa de la zona	0,022	0,015 a 0,029

Los intervalos salen de **1.000 remuestreos por bootstrap de las 87 horas** del período de prueba (las cotizaciones de una misma hora comparten recargo, así que se remuestrean horas completas). La ventaja sobre la tasa de la zona es **positiva en todo el intervalo**: el modelo aprende algo más que "dónde sube".



Cómo leer la matriz del modelo elegido (gradient boosting):

	Predijo sin recargo	Predijo con recargo
Real: sin recargo	**VN = 38.202** · acierto	**FP = 16.265** · falsa alarma
Real: con recargo	**FN = 2.394** · recargo no detectado	**VP = 2.534** · recargo detectado

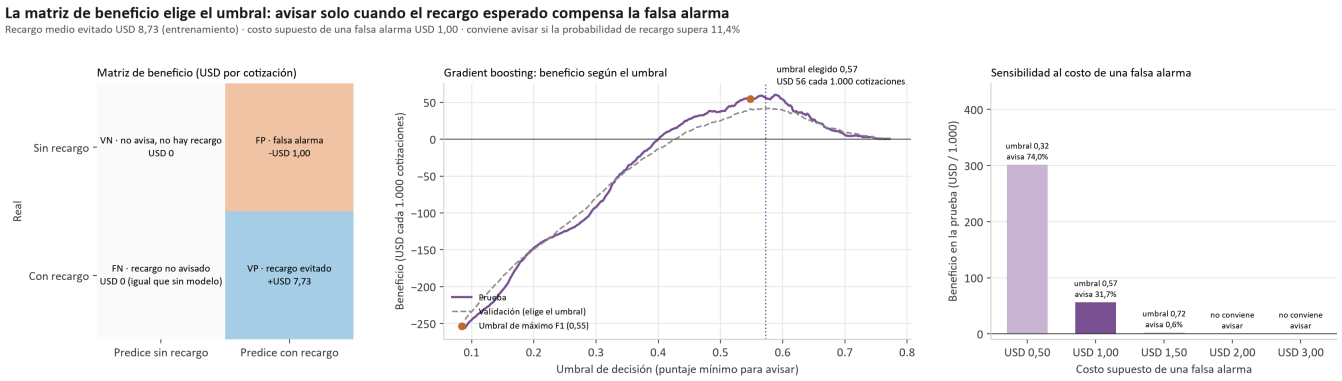
- **Accuracy** = (VP + VN) / total = **68,6%**, contra 91,7% de decir siempre que no.
- **Precisión** = VP / (VP + FP) = **13,5%**: de cada 100 alertas, 13 son recargos reales (el azar acierta 8).
- **Recall** = VP / (VP + FN) = **51,4%** de los recargos detectados.
- **Accuracy balanceada 60,8%** (azar = 50%). El modelo avisa en el 31,7% de las cotizaciones.

9 · Análisis con la matriz de beneficio

¿Qué nos conviene más: **evitar falsas alarmas** o **no perder recargos**? La matriz de beneficio le pone un valor en dólares a cada casilla de la matriz de confusión y elige el umbral que más conviene.

	Predice sin recargo	Predice con recargo (aviso)
Real: sin recargo	VN · USD 0	FP · **−USD 1,00** (compara o espera sin necesidad)
Real: con recargo	FN · USD 0 (paga el recargo, igual que sin modelo)	VP · **+USD 7,73** (evita el recargo y pierde el tiempo de comparar)

- **Recargo medio evitado: USD 8,73** (medido en las cotizaciones con recargo del entrenamiento).
- **Costo de una falsa alarma: USD 1,00**, unos 5 minutos de comparar o esperar. Es un **supuesto** del equipo: por eso mostramos la sensibilidad.
- **Regla que sale de la matriz:** conviene avisar si la probabilidad de recargo supera costo / recargo = **11,4%**.



- Con la matriz, el umbral del modelo elegido es **0,57**: avisa en el 31,7% de las cotizaciones, con precisión 13,5% y recall 51,4%, y gana **USD 56 cada 1.000 cotizaciones**.
- Con el umbral de máximo F1 (0,55) avisaba en el 38,5%, con precisión 13,1%: beneficio **USD 55**. **Avisaba de más.**

Costo de una falsa alarma	Precisión mínima	Umbral	Avisa en	Recall	Precisión	Beneficio / 1.000
USD 0,50	5,7%	0,32	74,0%	92,7%	10,4%	USD 301
USD 1,00	11,4%	0,57	31,7%	51,4%	13,5%	USD 56
USD 1,50	17,2%	0,72	0,6%	1,5%	21,5%	USD 2
USD 2,00	22,9%	no avisar	0,0%	0,0%	–	USD 0
USD 3,00	34,3%	no avisar	0,0%	0,0%	–	USD 0

Recargos a detectar	Umbral	Recall real	FN	FP	Precisión	Accuracy	Beneficio / 1.000
90%	0,27	96,5%	173	43.508	9,9%	26,5%	USD -113
80%	0,38	87,0%	639	34.152	11,2%	41,4%	USD -17
70%	0,45	81,4%	919	29.423	12,0%	48,9%	USD 27
60%	0,50	74,6%	1.251	26.289	12,3%	53,6%	USD 36
50%	0,54	63,4%	1.802	20.887	13,0%	61,8%	USD 55
40%	0,57	51,3%	2.400	16.229	13,5%	68,6%	USD 56
30%	0,60	35,2%	3.193	10.210	14,5%	77,4%	USD 54
20%	0,62	18,4%	4.020	4.905	15,6%	85,0%	USD 36
10%	0,66	8,2%	4.525	1.734	18,9%	89,5%	USD 23

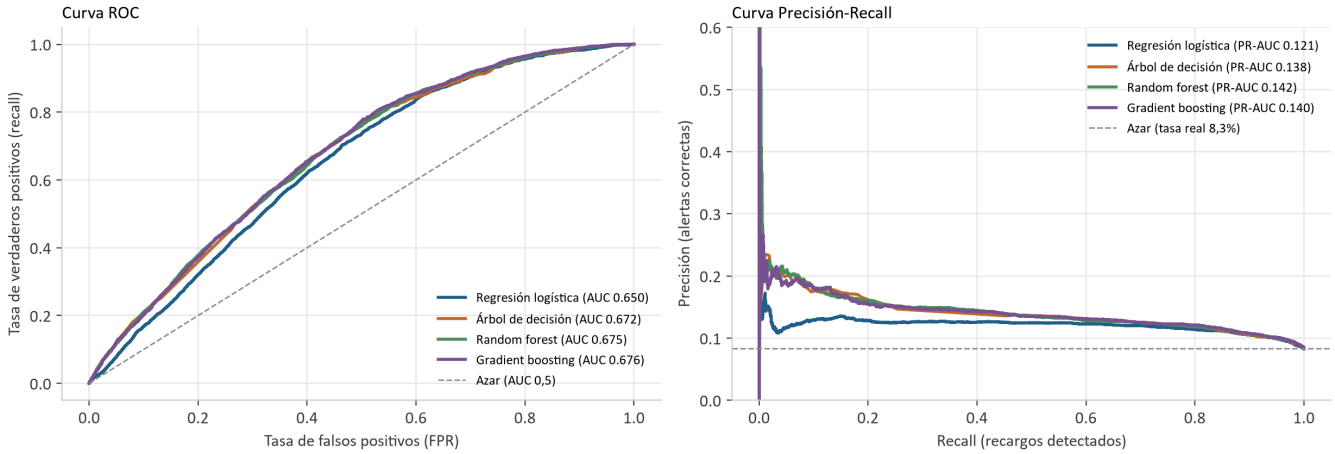
En qué conviene enfocarse:

- **En la precisión (menos falsas alarmas), no en detectar todos los recargos.** Para detectar el 90% de los recargos hay que avisar casi siempre, y las falsas alarmas se comen el beneficio.
- **El techo del dominio:** aun en su mejor tramo, el modelo no supera ~20% de precisión. El recargo depende de la oferta y la demanda en tiempo real, que no está en el dataset.
- **Si una falsa alarma le cuesta al pasajero USD 2 o más, no conviene avisar nunca.** El modelo sirve para avisos de bajo costo (por ejemplo, "conviene comparar con Uber"), no para decisiones caras.

10 · Curva ROC y AUC

Los modelos ordenan el riesgo mejor que el azar, pero con poco margen

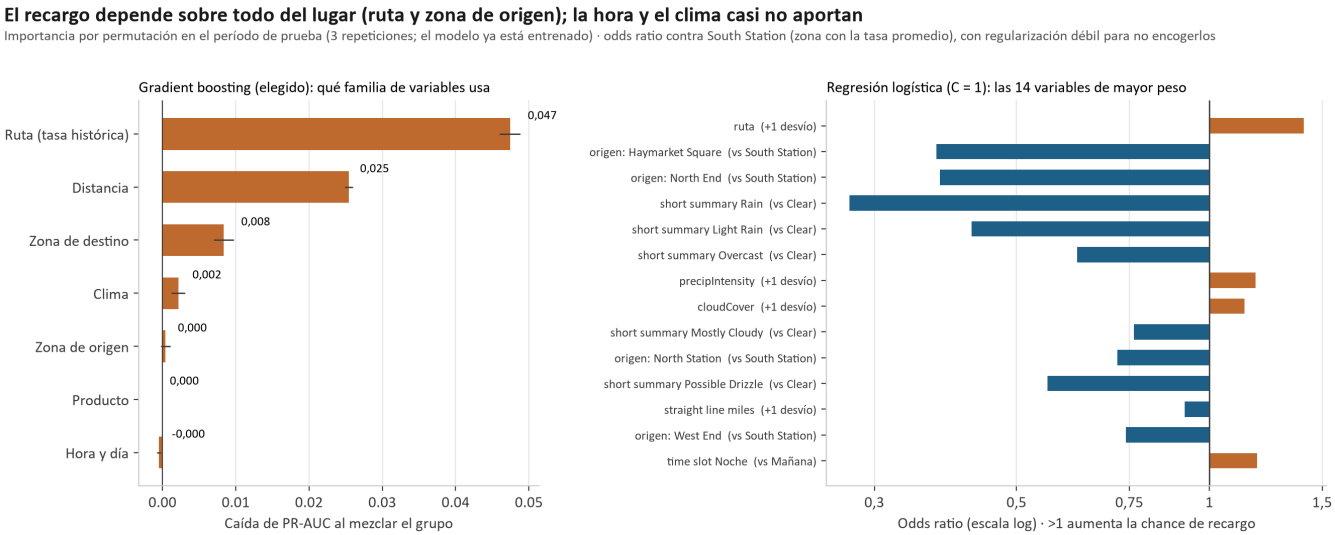
Período de prueba · con 8% de positivos, la curva Precisión-Recall es más exigente que la ROC



Cómo leer la curva ROC: cada punto es un umbral. El eje X es la tasa de falsas alarmas (FP / sin recargo) y el eje Y, el recall. La diagonal es el azar (AUC = 0,5); un modelo perfecto llega a la esquina superior izquierda (AUC = 1).

- **ROC-AUC entre 0,650 y 0,676:** los cuatro modelos están por encima del azar, pero lejos de un clasificador fuerte. Significa que si se toma al azar una cotización con recargo y una sin recargo, el modelo le da más puntaje a la que tiene recargo el 68% de las veces (gradient boosting).
- **IC 95% del ROC-AUC del modelo elegido:** 0,663 a 0,689.
- **La curva Precisión-Recall** es más exigente con 8% de positivos: la precisión se mantiene baja en casi todo el recorrido. El recargo es difícil de anticipar con estos datos.

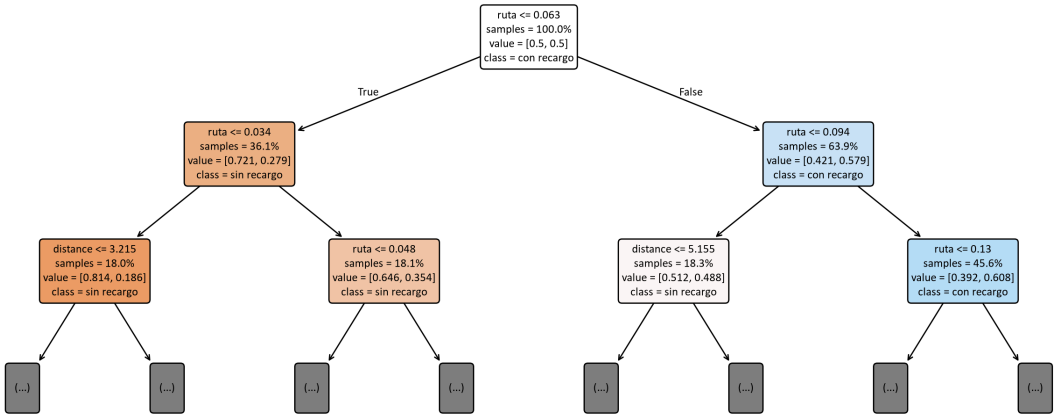
11 · ¿Qué aprendieron los modelos?



- **El lugar es lo que más importa:** la ruta y la zona de origen. La hora y el clima casi no aportan.
- Comparado con South Station (zona promedio), salir de **Northeastern University** multiplica la chance de recargo por 1,29 y de **Boston University**, por 1,24; salir de **Haymarket Square**, por 0,37.
- Los odds ratio salen de una logística con **regularización débil (C = 1)**: la logística elegida usa una C muy chica que los encoge hacia 1 (North End daría 0,65 en lugar de 0,38).

Las primeras reglas del árbol de decisión

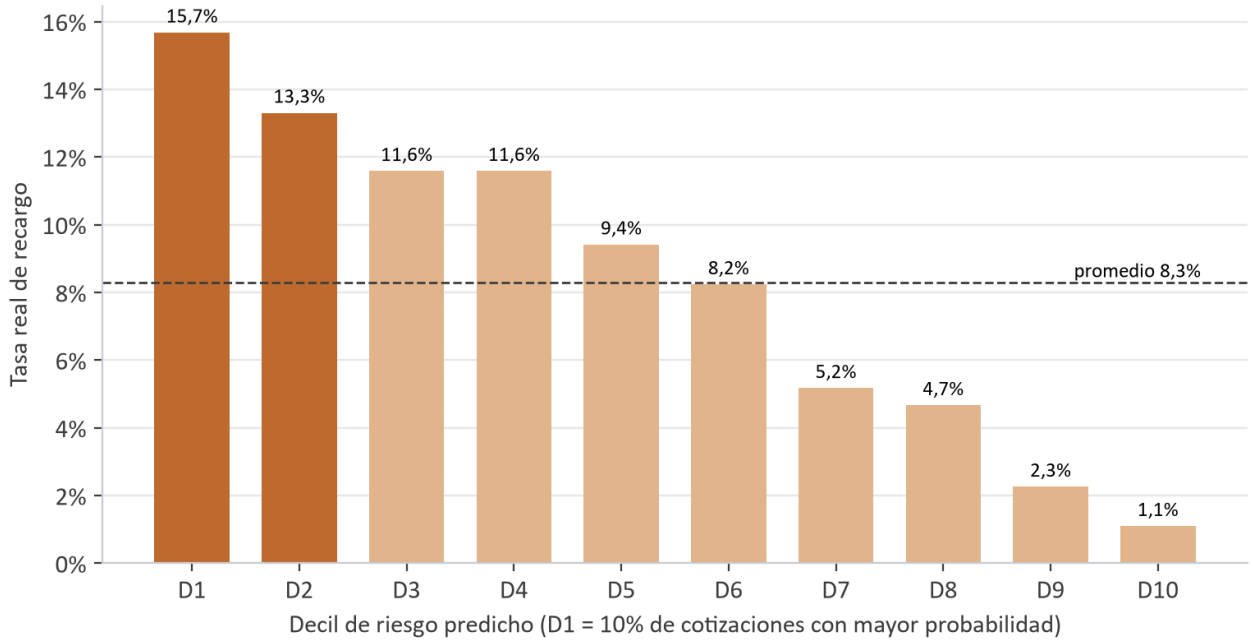
Tres primeros niveles · ruta = tasa histórica de recargo de la ruta en el entrenamiento · en las dummies, '≤ 0.5' significa 'no' · value = proporción [sin, con] recargo ponderada por los pesos de clase



Cómo leer el árbol: cada caja hace una pregunta (por ejemplo, *¿la tasa histórica de recargo de la ruta es menor a X?*). Si la respuesta es sí se baja a la izquierda; si no, a la derecha. `value` es la proporción [sin, con] recargo en esa caja (ponderada por los pesos de clase): cuanto más naranja, más chance de recargo. El árbol separa primero por **lugar** y después por **distancia**.

El 20% de mayor riesgo concentra el 34,9% de los recargos

Gradient boosting con pesos de clase · período de prueba · tasa real de recargo en cada decil de probabilidad predicha



El modelo no adivina viaje por viaje, pero **ordena el riesgo**: el 10% de cotizaciones más riesgosas tiene 15,7% de recargos (1,9 veces el promedio) y el 10% menos riesgoso, 1,1%. El 20% más riesgoso concentra el **35%** de los recargos.

12 · Validación: por fecha vs mezclada

La **validación cruzada** repite el entrenamiento varias veces con distintas partes de los datos. En cada fold el balanceo se aplica solo a la parte de entrenamiento y se valida contra **datos reales**. Comparamos dos formas de armar los folds:

Modelo	CV temporal en orden (4 folds)	CV mezclada (5 folds estratificados)	Diferencia
Regresión logística	0,120 ± 0,004	0,126 ± 0,003	+5%
Árbol de decisión	0,125 ± 0,014	0,150 ± 0,005	+20%
Random forest	0,126 ± 0,006	0,312 ± 0,005	+147%
Gradient boosting	0,136 ± 0,012	0,178 ± 0,003	+31%

Modelo	Prueba: 4 días nuevos	Prueba: 25% al azar	Diferencia
Árbol de decisión	0,138	0,153	+11%
Random forest	0,142	0,309	+117%
Gradient boosting	0,140	0,172	+23%

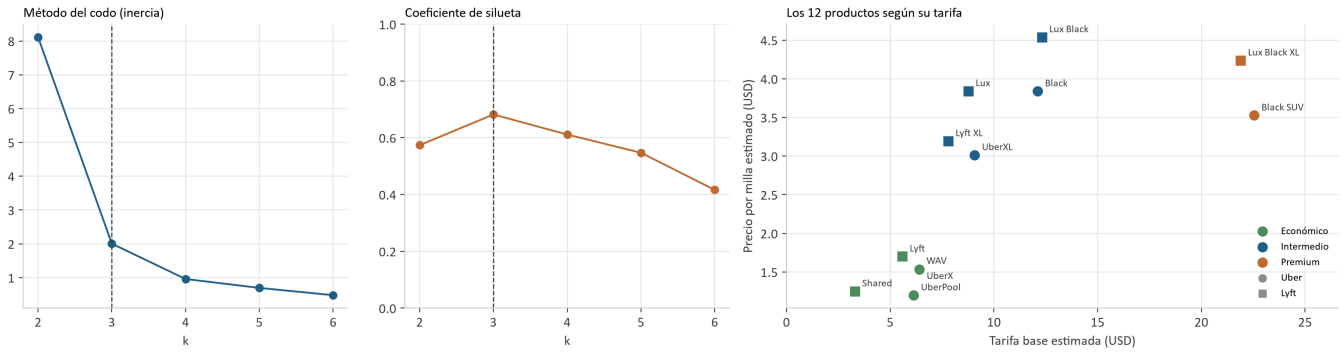
Mezclar las fechas hace parecer mejores a los modelos, porque reconocen cotizaciones del mismo minuto y ruta que vieron al entrenar. Por eso elegimos con la validación cruzada **temporal**: es la estimación honesta de lo que pasaría con días nuevos.

13 · Familias de tarifa (K-Means)

Para cada uno de los 12 productos calculamos **cuánto cobra por subir** (tarifa base) y **cuánto por milla**, con viajes sin recargo. Después los agrupamos con K-Means: el codo y la silueta marcan **k = 3** (silueta 0,68).

Los 12 productos de Uber y Lyft forman 3 familias de tarifa

K-Means sobre tarifa base y precio por milla (estandarizados), estimados con viajes sin recargo del entrenamiento · k = 3: máximo coeficiente de silueta



Familia	Productos	Tarifa base	Por milla
Económico	Shared, Lyft, UberPool, WAV, UberX	USD 3,3 a 6,4	USD 1,20 a 1,70
Intermedio	Lyft XL, Lux, UberXL, Black, Lux Black	USD 7,8 a 12,3	USD 3,01 a 4,54
Premium	Lux Black XL, Black SUV	USD 21,9 a 22,5	USD 3,53 a 4,24

- **Uber y Lyft arman el precio igual:** cada producto de Uber cae en la misma familia que su equivalente de Lyft.
- **Por qué los viajes cortos son caros por milla (H4):** la tarifa base se cobra siempre. Un UberX de 1 milla sale USD 7,94 por milla; uno de 5 millas, USD 2,81.

14 · Conclusiones

Hipótesis	Resultado
H1 · Producto y distancia definen el precio	✓ Confirmada (R^2 = 0,967)
H2 · Uber y Lyft difieren según el nivel	✓ Confirmada
H3 · Hay patrones horarios	✘ No se confirma
H4 · Hay rutas más caras por milla	✓ Confirmada (las cortas, por la tarifa base)
H5 · El mal clima encarece	✘ Rechazada
H6 · Hay segmentos tarifarios	✓ Confirmada (3 familias de productos)

Respuesta al problema

1. **El precio es predecible:** con el producto, la distancia y el multiplicador se estima con un error de USD 1,08 (USD 1,32 sin el multiplicador).
2. **El recargo es lo difícil de anticipar:** depende del **lugar**, no de la hora ni del clima. Lo demás depende de la oferta y la demanda en tiempo real, que no están en los datos (ROC-AUC 0,676).
3. **La accuracy sola engaña:** 68,6% del modelo contra 91,7% de decir siempre que no. La mejora real se ve en la accuracy balanceada (60,8%) y en el beneficio.
4. **La matriz de beneficio define cómo usarlo:** avisos selectivos, de bajo costo para el pasajero (USD 56 de beneficio cada 1.000 cotizaciones con el supuesto de USD 1 por falsa alarma).
5. **Valor práctico:** si salís de Back Bay, Fenway o las universidades, conviene **comparar con Uber** o caminar a una zona vecina.

Próximo paso (Entrega 4): contar esta historia para el pasajero, el conductor y la plataforma.

Anexo · Dónde está cada cosa

Carpeta	Contenido
`1_Informe/`	Informe completo, con todos los detalles técnicos
`3_Codigo/`	`modelado_entrega3.py` : reproduce todo
`4_Datasets/`	Datasets de modelado y balanceados
`5_Graficos/` y `6_Resultados/`	Figuras y tablas
`Modelos/README.md`	Cómo hicimos cada modelo, paso a paso